Progetto di Statistica e Analisi dei Dati

Analisi di un dataset su obesità e abitudini di vita

Gabriele Santoro – 0522502066

Febbraio 2026

Indice

1 Introduzione e contesto del problema **3**
1.1 Dominio applicativo . . . 3
1.2 Motivazione e obiettivo generale del progetto . . . 3
1.3 Research Questions (RQ) . . . 4

2 Descrizione del dataset **5**
2.1 Origine e struttura del dataset . . . 5
2.2 Unità statistiche e variabili disponibili . . . 5
2.3 Dataset one-vs-rest: implicazioni . . . 6

3 Pre-processing e pulizia dei dati **7**
3.1 Controllo valori mancanti e gestione . . . 7
3.2 Analisi dell'arrotondamento e deduplicazione . . . 7
3.3 Controllo outlier e range plausibili . . . 9

4 Analisi esplorativa (EDA) **10**
4.1 Statistiche descrittive univariate e visualizzazioni principali . . . 10
4.1.1 Distribuzioni delle variabili . . . 10
4.2 Dipendenze tra variabili . . . 18
4.2.1 Relazioni tra variabili numeriche . . . 18
4.2.2 Relazioni tra variabili categoriche . . . 20
4.3 Anomalie, bias e limitazioni osservate . . . 26
4.3.1 Artefatti numerici e generazione sintetica (SMOTE) . . . 26
4.3.2 Squilibrio nelle classi categoriche (Class Imbalance) . . . 27
4.3.3 Bias demografico e culturale . . . 27
4.3.4 Appiattimento informativo e variabili Proxy . . . 28
4.3.5 Limiti del Self-Reporting . . . 28

5 Analisi dell'utilità delle feature **29**
5.1 Criteri di utilità e metodologie adottate . . . 29
5.2 Analisi dei coefficienti di correlazione . . . 29
5.2.1 Analisi delle variabili qualitative (Cramér's V) . . . 29
5.2.2 Analisi delle variabili quantitative . . . 31
5.3 Analisi di Pareto (Variabilità delle feature) . . . 32
5.4 Potere discriminante del Clustering (K-Means) . . . 33
5.5 Riduzione della complessità tramite MCA . . . 34
5.6 Costruzione di nuove feature (Feature Engineering) . . . 36
5.6.1 Diet Quality Index (DQI) . . . 36
5.6.2 Activity Index (AI): Analisi dello Stile di Vita . . . 37

6 Generazione e valutazione di dati sintetici **39**
6.1 Scelta del modello LLM e motivazione basata su benchmark 39
6.1.1 Selezione del modello: GPT-5.2 39
6.1.2 Strategia di Prompt Engineering 39
6.2 Procedura di generazione del dataset sintetico 40
6.2.1 Iterazioni e Ottimizzazione del Prompt 40
6.2.2 Esecuzione, Parsing e Validazione 41
6.3 Valutazione statistica dei dati sintetici 41
6.3.1 Confronto sulle variabili numeriche 41
6.3.2 Confronto sulle variabili qualitative 41
6.3.3 Confronto su feature derivate 42
6.3.4 Verifica dell'adattamento a distribuzioni statistiche note 43
6.3.5 Variabili con adattamento a distribuzioni note 43
6.4 Discussione dei risultati e criticità 45
6.4.1 Risultati principali 45
6.4.2 Criticità e interpretazione 46
6.4.3 Implicazioni pratiche 46

7 Conclusioni e sviluppi futuri **47**
7.1 Risposte alle RQ 47
7.2 Limiti del lavoro 48
7.2.1 Limiti legati al dataset 48
7.2.2 Limiti metodologici di validazione 48
7.2.3 Limiti sulle feature derivate 49
7.2.4 Riproducibilità e robustezza della generazione 49

A Appendice A: Formule e dettagli di calcolo **50**
A.1 Notazione generale 50
A.2 Frequenze relative e percentuali (variabili qualitative) 50
A.3 Stima di densità kernel (KDE) 50
A.4 Body Mass Index (BMI) 50
A.5 Feature derivate (indici) 50

B Appendice B: Materiale supplementare **51**
B.1 Validazione del Diet Quality Index (DQI) 51
B.2 Validazione dell'Activity Index (AI) 53
B.3 Confronto tra dati reali e sintetici 55
B.3.1 Variabili numeriche 55
B.3.2 Variabili qualitative 55
B.3.3 Feature derivate 55
B.4 Analisi sulle distribuzioni 56
B.4.1 Distribuzione Normale 56
B.4.2 Distribuzione di Bernoulli 58

1 Introduzione e contesto del problema

1.1 Dominio applicativo

L'obesità è un fenomeno multifattoriale di rilevanza sanitaria, influenzato da componenti biologiche, ambientali e comportamentali. In ambito di sanità pubblica e prevenzione, è utile analizzare congiuntamente variabili antropometriche, caratteristiche misurabili del corpo umano riferibili ad un'unità di misura, e abitudini di vita per descrivere profili di rischio e identificare pattern ricorrenti all'interno di una popolazione.

Il dataset analizzato descrive individui tramite misure fisiche (età, altezza e peso) e un insieme di variabili legate allo stile di vita, tra cui abitudini alimentari (ad es. consumo di cibi ipercalorici, consumo di verdure, snack tra i pasti, consumo di acqua) e comportamenti come attività fisica e tempo trascorso su dispositivi. Queste informazioni sono rappresentate mediante variabili quantitative, binarie e ordinali codificate numericamente. Inoltre è presente una variabile di classe (`class`) che, nel presente lavoro, è stata considerata in un contesto *one-vs-rest*, risultando, successivamente ad un'analisi approfondita, composta da soli elementi della classe *Obesity Level 1*.

Dal punto di vista applicativo, l'analisi statistica di tali dati consente di: (i) valutare la qualità e la coerenza interna delle feature disponibili, (ii) studiare la struttura delle dipendenze tra variabili (ad es. relazioni tra comportamenti e misure fisiche), (iii) individuare eventuali anomalie o bias di codifica e (iv) discutere l'eventuale necessità di nuove feature derivate, come indici sintetici di dieta o attività, verificandone la coerenza e l'utilità nel contesto specifico del dataset considerato.

1.2 Motivazione e obiettivo generale del progetto

L'obiettivo generale del progetto è applicare in modo pratico gli strumenti di Statistica e Analisi dei Dati a un dataset reale, sviluppando un'analisi completa che includa esplorazione, pulizia, trasformazione delle variabili e valutazione critica dei risultati.

In particolare, la motivazione nasce dalla necessità di comprendere la qualità informativa delle feature disponibili in un dataset relativo a obesità e abitudini di vita, verificando coerenza delle codifiche, presenza di anomalie e struttura di dipendenze tra variabili. Il dataset considerato, nella versione utilizzata in questo lavoro, è organizzato in modalità *one-vs-rest* e contiene osservazioni appartenenti ad una sola classe (*Obesity Level 1*); ciò rende centrale un'analisi intra-classe orientata alla descrizione e alla validazione delle feature.

L'obiettivo operativo è quindi articolato nei seguenti punti:

- effettuare un'analisi esplorativa delle distribuzioni e delle relazioni tra variabili, tramite statistiche descrittive e visualizzazioni;
- eseguire pre-processing e controlli di qualità (valori mancanti, range plausibili, outlier, correttezza delle codifiche);
- valutare l'utilità delle feature esistenti tramite criteri statistici (variabilità, ridondanza, coerenza con variabili fisiche);
- proporre e discutere, quando opportuno, nuove feature derivate (*feature engineering*) e verificarne la coerenza interna e l'effettiva utilità nel contesto del dataset analizzato.

Infine, in linea con le possibili estensioni previste dal progetto, una ulteriore fase consiste nella generazione di dati sintetici mediante modelli linguistici di grandi dimensioni (LLM) e nel confronto statistico tra dati reali e sintetici, al fine di valutare se le principali proprietà distribuzionali e le dipendenze tra variabili vengano preservate.

1.3 Research Questions (RQ)

In coerenza con gli obiettivi del progetto, lo studio è guidato dalle seguenti Research Questions:

- **RQ1 (Qualità e coerenza dei dati).** Le variabili del dataset presentano codifiche coerenti e valori plausibili? Sono presenti anomalie (valori fuori range, livelli inconsistenti, outlier evidenti) o possibili bias di campionamento?
- **RQ2 (Struttura e dipendenze tra variabili).** Quali relazioni statistiche emergono tra le feature antropometriche (es. peso, altezza, età) e le variabili legate allo stile di vita? Esistono ridondanze o dipendenze forti tra alcune feature che suggeriscono collinearità o informazione duplicata?
- **RQ3 (Utilità delle feature disponibili in un contesto intra-classe).** Considerando che il dataset è in configurazione *one-vs-rest* e contiene solo la classe *Obesity Level 1*, quali feature risultano maggiormente informative nel descrivere l'eterogeneità interna del campione (variabilità e pattern osservabili)?
- **RQ4 (Necessità ed efficacia di feature derivate).** È utile introdurre nuove feature sintetiche (feature engineering) derivate dalle variabili comportamentali? Tali feature risultano coerenti con le variabili di partenza e aggiungono informazione misurabile rispetto alle feature originali?
- **RQ5 (Fedeltà statistica dei dati sintetici).** Nel caso di generazione di dati sintetici tramite LLM, i dati sintetici preservano le principali proprietà statistiche dei dati reali (statistiche descrittive, distribuzioni marginali e dipendenze tra feature)?
- **RQ6 (Diversità e rischio di mode collapse)** I dati sintetici mostrano adeguata variabilità (assenza di duplicati, code distribuzionali non "schiacciate", preservazione di categorie rare) oppure evidenziano concentrazione su profili "tipici" e perdita di diversità?

2 Descrizione del dataset

2.1 Origine e struttura del dataset

Il dataset utilizzato in questo progetto deriva dall'UCI Machine Learning Repository e si intitola *Estimation of Obesity Levels Based On Eating Habits and Physical Condition.* [3] Il dataset originale riguarda la stima dei livelli di obesità in individui provenienti da Messico, Perù e Colombia, sulla base di abitudini alimentari e condizione fisica. [3, 2]

Nel repository UCI il dataset è descritto come multivariato, con 2111 istanze e 16 feature (oltre alla variabile target) e senza valori mancanti dichiarati. [3] Nel presente lavoro è stato analizzato il sottoinsieme relativo alla classe *Obesity Level 1*, in cui la variabile di classe (`class`) risulta costante e pari a 1 per tutte le osservazioni.

2.2 Unità statistiche e variabili disponibili

L'unità statistica del dataset è il singolo individuo, descritto tramite misure antropometriche e un insieme di variabili legate ad abitudini alimentari e stile di vita. Nel dataset considerato sono presenti $n = 351$ osservazioni e 17 colonne complessive (16 feature esplicative + 1 variabile di classe).

Le variabili possono essere raggruppate in base alla loro natura statistica (continue, binarie, ordinali) e alla relativa codifica, riportata di seguito.

Variabili continue (antropometriche).

- `AGE`: età (range osservato: 15–52).
- `Height`: altezza in metri (range osservato: 1.50–1.98).
- `Weight`: peso in kg (range osservato: 75–125).

Variabili binarie.

- `Gender` ($\{0, 1\}$): variabile di genere codificata.
- `fhwo` ($\{0, 1\}$): presenza di casi di sovrappeso/obesità in famiglia.
- `FAVC` ($\{0, 1\}$): consumo frequente di cibi ipercalorici.
- `SMOKE` ($\{0, 1\}$): abitudine al fumo.
- `SCC` ($\{0, 1\}$): monitoraggio delle calorie.

Variabili ordinali/categoriali codificate.

- `FCVC` ($\{1, 2, 3\}$): consumo di verdure.
- `NCP` ($\{1, 2, 3, 4\}$): numero di pasti principali giornalieri.
- `CAEC` ($\{0, 1, 2, 3\}$): consumo di cibo tra i pasti.
- `CH2O` ($\{1, 2, 3\}$): consumo giornaliero di acqua.
- `FAF` ($\{0, 1, 2, 3\}$): frequenza di attività fisica.
- `TUE` ($\{0, 1, 2\}$): tempo su dispositivi / sedentarietà.
- `CALC` ($\{0, 1, 2\}$): consumo di alcol.
- `MTRANS` ($\{0, 1, 2, 3\}$): modalità di trasporto.

Variabile di classe.

- `class`: nel dataset analizzato è costante ed è pari a 1 per tutte le osservazioni, coerentemente con l'impostazione one-vs-rest.

In questa fase descrittiva, le variabili ordinali vengono trattate come livelli ordinati; eventuali trasformazioni (standardizzazione, normalizzazione, costruzione di indici compositi) vengono motivate e applicate nelle sezioni successive ove necessario.

2.3 Dataset one-vs-rest: implicazioni

Nel dataset utilizzato in questo progetto la variabile di classe `class` è costante e assume valore 1 per tutte le $n = 351$ osservazioni; ciò è coerente con un'impostazione *one-vs-rest* in cui è stato estratto un sottoinsieme relativo a una sola classe (*Obesity Level 1*). Questa scelta influenza in modo sostanziale le analisi statistiche che è possibile (o non è possibile) svolgere.

Implicazioni metodologiche principali.

- **Assenza di classificazione supervisionata.** Non essendoci variabilità nella variabile target, non è possibile allenare e valutare un classificatore (o una regressione con target informativo), né calcolare metriche come accuracy, AUC, precision/recall.
- **Analisi principalmente descrittiva e intra-classe.** Le analisi si concentrano sulla descrizione della popolazione rappresentata, sulla variabilità interna delle feature e sull'identificazione di pattern comportamentali/antropometrici all'interno della sola classe disponibile.
- **Relazioni tra variabili senza confronto tra gruppi.** È possibile studiare dipendenze tra feature (correlazioni, associazioni tra variabili ordinali/binarie, ridondanze), ma non è possibile interpretare tali relazioni come "discriminanti" tra classi, poiché manca un gruppo di confronto.

Conseguenze operative sull'analisi.

- **Qualità dei dati e coerenza delle codifiche diventano centrali:** controlli di range, livelli osservati, outlier e plausibilità assumono un ruolo prioritario.
- **Feature engineering:** eventuali nuove feature (es. BMI o indici compositi di stile di vita) possono essere valutate per coerenza interna e interpretabilità, ma non per capacità predittiva rispetto alla classe.
- **Analisi non supervisionate:** tecniche come clustering o detection di anomalie possono essere utilizzate per segmentare la popolazione o identificare osservazioni atipiche, ma i risultati vanno interpretati come struttura interna del campione, non come separazione tra classi.

3 Pre-processing e pulizia dei dati

3.1 Controllo valori mancanti e gestione

La prima fase del pre-processing ha riguardato la verifica della presenza di valori mancanti (NA) in ciascuna variabile del dataset. Nel dataset analizzato non sono emersi valori mancanti: per tutte le colonne si osserva `missing_n = 0` (0.0% sul totale delle $n = 351$ osservazioni).

Di conseguenza non è stato necessario applicare tecniche di imputazione o rimozione di record/feature. Tuttavia, per completezza metodologica, in presenza di missingness le strategie standard sarebbero: (i) eliminazione listwise/pairwise quando la quota di missing è trascurabile e non introduce bias rilevante oppure (ii) imputazione (media/mediana/moda) per preservare la numerosità campionaria in analisi multivariate o di modellazione.

3.2 Analisi dell'arrotondamento e deduplicazione

Prima di procedere con controlli di range plausibili e outlier, è stata valutata la possibilità di arrotondare le variabili continue per migliorare leggibilità e "realismo" dei valori, verificando che tale trasformazione non alterasse in modo sostanziale le statistiche descrittive. A tal fine è stata condotta una *sensitivity analysis* confrontando dataset originale e dataset arrotondato.

Nel nostro caso l'arrotondamento è stato applicato a `AGE` (0 cifre decimali), `Height` (2 decimali) e `Weight` (1 decimale). Il confronto delle statistiche aggregate (media, deviazione standard, min e max) mostra variazioni contenute tra originale e arrotondato (ad es. scostamento massimo in valore assoluto: $\Delta\text{media} \leq 0.0182$, $\Delta\text{std} \leq 0.0172$, $\Delta\text{min} \leq 0.0794$, $\Delta\text{max} \leq 0.0942$).

La criticità principale non riguarda quindi le statistiche globali, bensì la comparsa di duplicati esatti introdotti dall'arrotondamento: nel dataset originale non sono presenti righe duplicate, mentre dopo arrotondamento compaiono 12 duplicati. Per evitare ridondanza e possibili effetti indesiderati nelle analisi successive, i duplicati sono stati rimossi tramite deduplicazione sul record completo, riducendo la numerosità campionaria da 351 a 339 osservazioni.

L'impatto della deduplicazione è stato verificato confrontando nuovamente le statistiche descrittive tra dataset originale e dataset arrotondato deduplicato, riscontrando variazioni non sostanziali a livello aggregato (scostamento massimo: $\Delta\text{media} \leq 0.0903$, $\Delta\text{std} \leq 0.1252$).

Impatto dell'arrotondamento sulle statistiche descrittive. Per valutare l'impatto dell'arrotondamento, sono state confrontate alcune statistiche descrittive (media, deviazione standard, mediana, IQR, min, max) prima e dopo la trasformazione, separatamente per `AGE`, `Height` e `Weight`. Oltre alle differenze nelle statistiche aggregate, è stato anche quantificato quante osservazioni risultano effettivamente modificate dall'arrotondamento.

Variabile	Decimali	Valori modificati	% su 351
AGE	0	258	73.50
Height	2	291	82.91
Weight	1	265	75.50

Tabella 1: Numero e percentuale di valori modificati dall'arrotondamento per ciascuna variabile continua.

Statistica	**Prima**	**Dopo**	**Differenza**
Media	25.884941	25.903134	0.018193
Deviazione Standard	7.755700	7.772976	0.017277
Mediana	22.975526	23.000000	0.024474
IQR (Q3-Q1)	8.905919	9.000000	0.094081
Min	15.000000	15.000000	0.000000
Max	52.000000	52.000000	0.000000

Tabella 2: Confronto statistiche descrittive prima/dopo arrotondamento per `AGE` (0 decimali).

Statistica	**Prima**	**Dopo**	**Differenza**
Media	1.693804	1.693447	-0.000357
Deviazione Standard	0.098414	0.098278	-0.000136
Mediana	1.681855	1.680000	-0.001855
IQR (Q3-Q1)	0.162819	0.160000	-0.002819
Min	1.500000	1.500000	0.000000
Max	1.980000	1.980000	0.000000

Tabella 3: Confronto statistiche descrittive prima/dopo arrotondamento per `Height` (2 decimali).

Statistica	**Prima**	**Dopo**	**Differenza**
Media	92.870198	92.868661	-0.001537
Deviazione Standard	11.485987	11.486655	0.000668
Mediana	90.744965	90.700000	-0.044965
IQR (Q3-Q1)	21.597782	21.650000	0.052218
Min	75.000000	75.000000	0.000000
Max	125.000000	125.000000	0.000000

Tabella 4: Confronto statistiche descrittive prima/dopo arrotondamento per `Weight` (1 decimale).

3.3 Controllo outlier e range plausibili

In questa fase sono stati effettuati controlli di plausibilità su *tutte* le variabili del dataset. La strategia adottata distingue tra: (i) variabili continue, per cui è possibile applicare criteri quantitativi di outlier detection, e (ii) variabili codificate (binarie/ordinali), per cui la verifica principale riguarda la coerenza dei livelli e l'assenza di codici non ammessi.

Variabili continue: range e outlier (IQR). Per `AGE`, `Height` e `Weight` sono stati verificati i range osservati, e sono stati identificati potenziali outlier tramite la regola di Tukey:

$$\text{outlier se } x < Q_1 - 1.5 \cdot IQR \quad \text{oppure} \quad x > Q_3 + 1.5 \cdot IQR.$$

Variabile	Min	Max	Outlier (IQR)
AGE	15.00	52.00	8
Height	1.50	1.98	0
Weight	75.00	125.00	0

Tabella 5: Range osservati e numero di potenziali outlier secondo la regola IQR.

I potenziali outlier individuati su `AGE` sono stati mantenuti nel dataset, poiché i valori risultano comunque plausibili nel contesto applicativo e non emergono anomalie analoghe sulle variabili fisiche.

Variabili binarie e ordinali: coerenza dei livelli e codici fuori dominio. Per tutte le variabili codificate (`Gender`, `fhwo`, `FAVC`, `SMOKE`, `SCC`, `FCVC`, `NCP`, `CAEC`, `CH2O`, `FAF`, `TUE`, `CALC`, `MTRANS`) è stato verificato che i valori osservati appartengano ai rispettivi insiemi di codifica attesi (es. binarie in $\{0, 1\}$ e ordinali in insiemi discreti predefiniti). Non sono stati riscontrati codici fuori dominio; di conseguenza non è stata necessaria alcuna correzione o ricodifica.

Nota operativa. Per le variabili binarie/ordinali non è stato applicato un criterio IQR, in quanto l'interpretazione di "valore estremo" su codifiche discrete è meno informativa di controlli di coerenza (codici validi) e di controlli di frequenza (livelli molto rari), che verranno eventualmente discussi nell'analisi esplorativa.

4 Analisi esplorativa (EDA)

4.1 Statistiche descrittive univariate e visualizzazioni principali

In questa sezione viene svolta un'analisi esplorativa univariata, con l'obiettivo di descrivere ciascuna variabile singolarmente prima di passare a eventuali relazioni tra variabili. Per le variabili numeriche si riportano le principali statistiche descrittive (misure di posizione e dispersione) e rappresentazioni grafiche standard. In particolare, l'istogramma consente di osservare la forma della distribuzione (asimmetrie ed eventuale multimodalità), mentre il boxplot sintetizza mediana, quartili e possibili valori estremi. Per le variabili non numeriche si utilizzano grafici di distribuzione basati su frequenze/percentuali, utili per evidenziare eventuali sbilanciamenti tra categorie o livelli. Le visualizzazioni sono accompagnate da didascalie e riferimenti nel testo per rendere la lettura più chiara e la sezione facilmente consultabile. Nel complesso, questa panoramica supporta la comprensione delle caratteristiche di base del dataset e orienta le scelte delle analisi successive.

4.1.1 Distribuzioni delle variabili

Di seguito si riportano, per ciascuna variabile, i grafici univariati adottati (istogramma e boxplot per le variabili numeriche; grafico di distribuzione per le altre), con le corrispondenti statistiche descrittive quando applicabile.

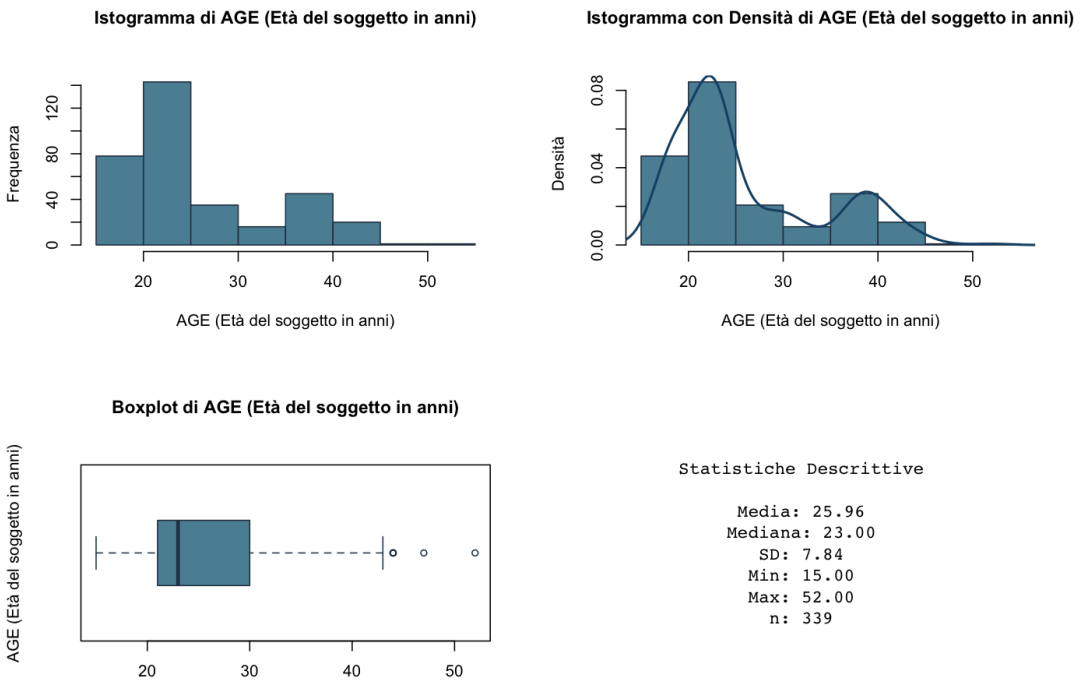

Figura 1: Distribuzione di `AGE`

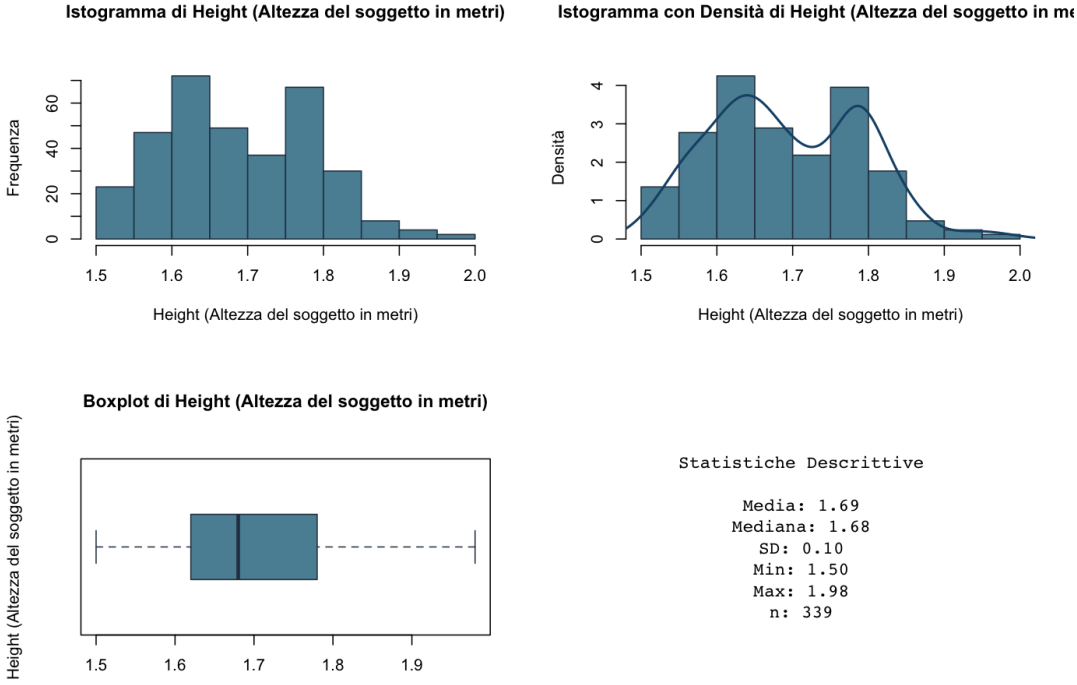

Figura 2: Distribuzione di `Height`

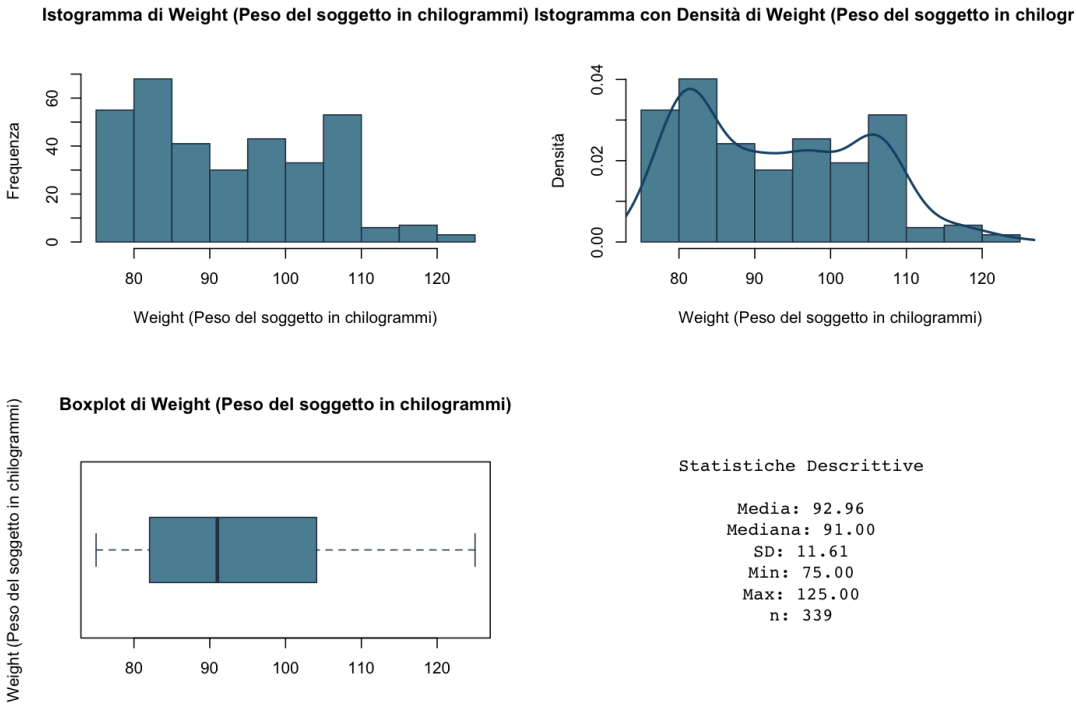

Figura 3: Distribuzione di `Weight`

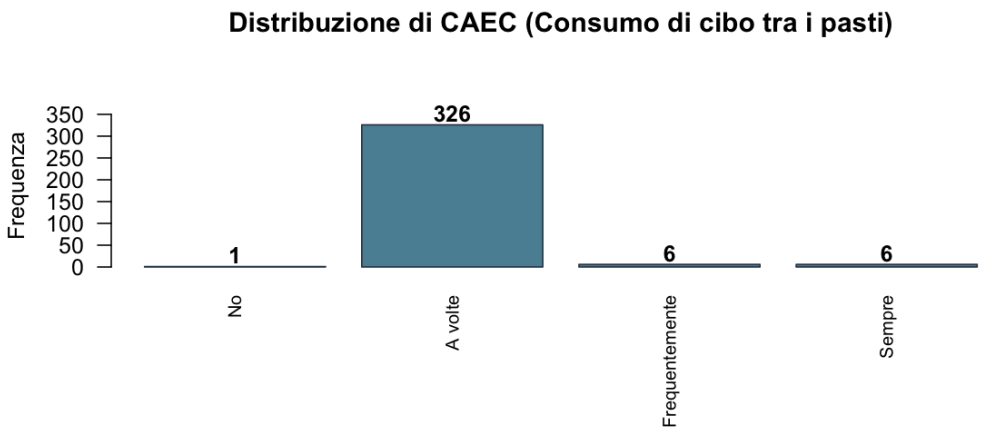

Figura 4: Distribuzione di `CAEC`

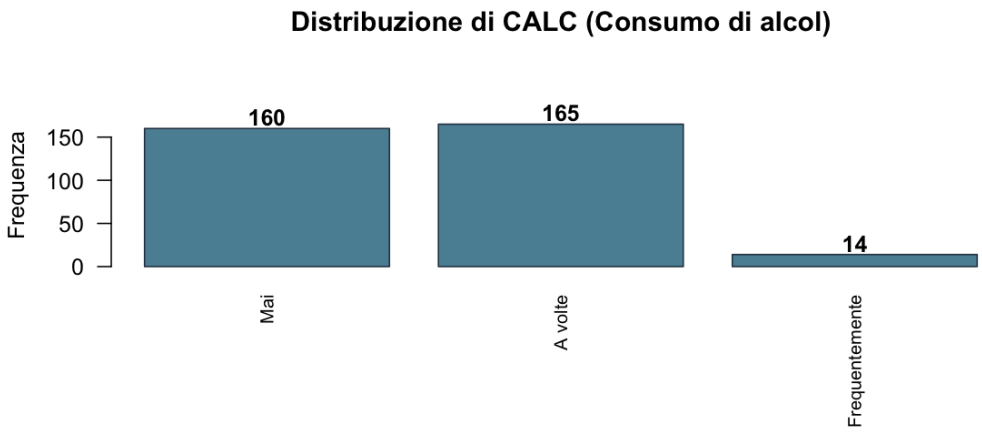

Figura 5: Distribuzione di `CALC`

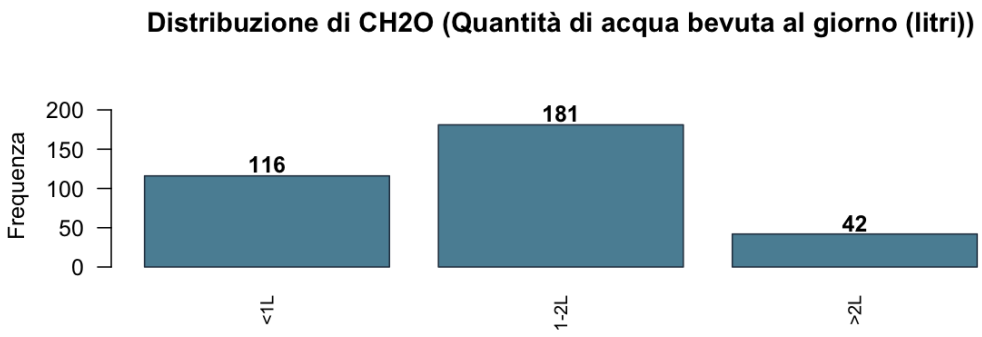

Figura 6: Distribuzione di `CH2O`

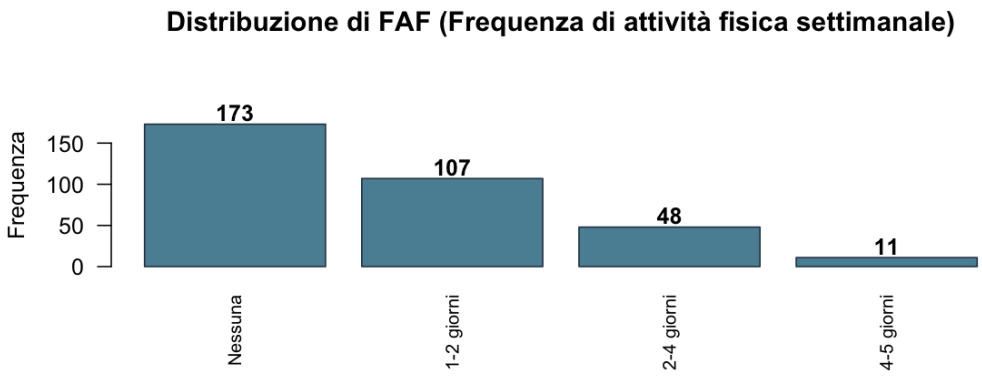

Figura 7: Distribuzione di `FAF`

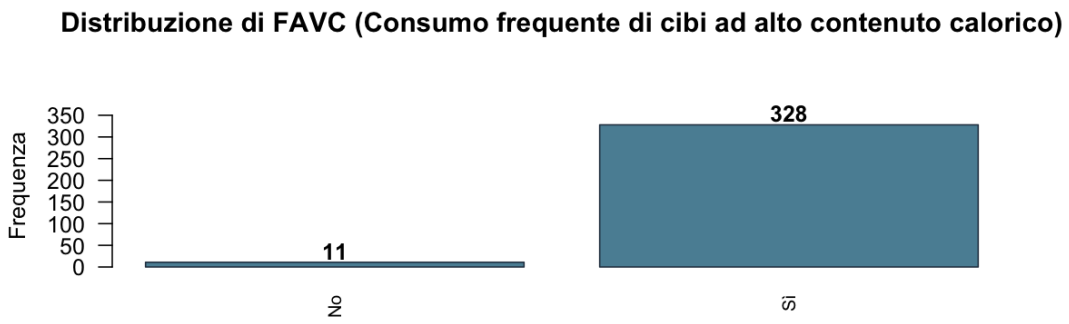

Figura 8: Distribuzione di `FAVC`

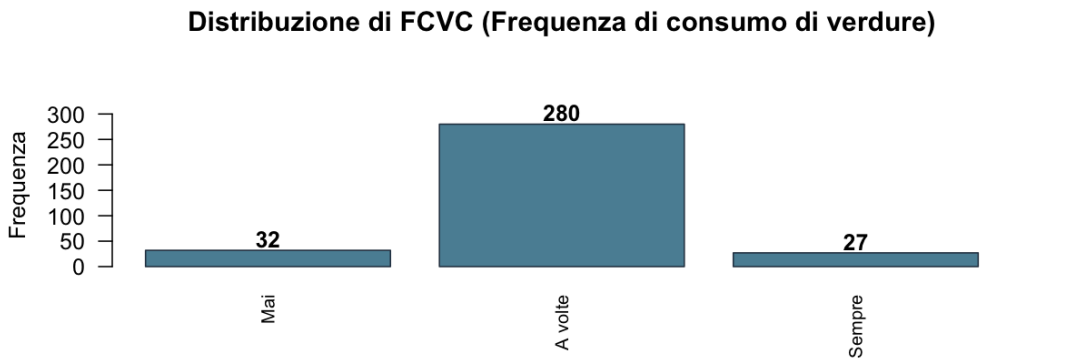

Figura 9: Distribuzione di `FCVC`

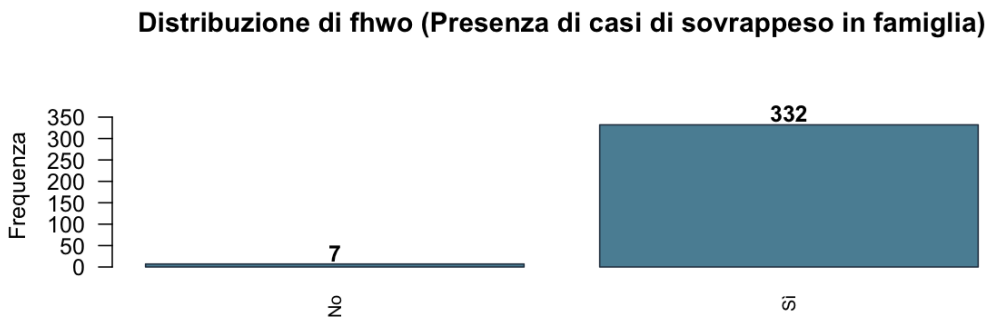

Figura 10: Distribuzione di `fhwo`

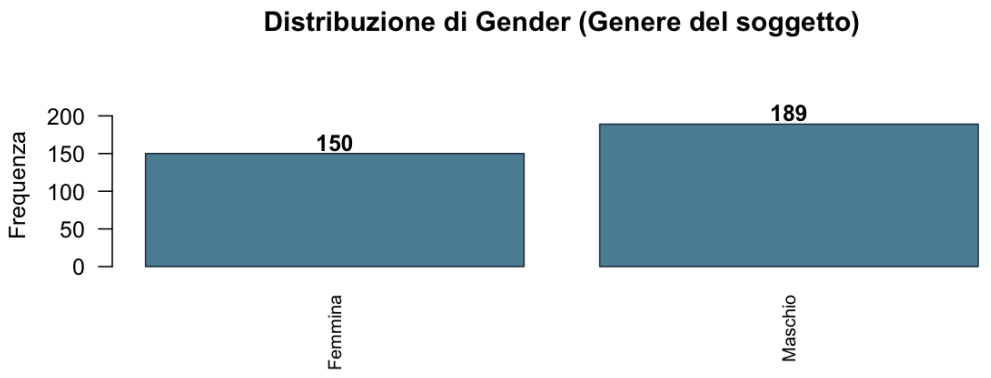

Figura 11: Distribuzione di `GENDER`

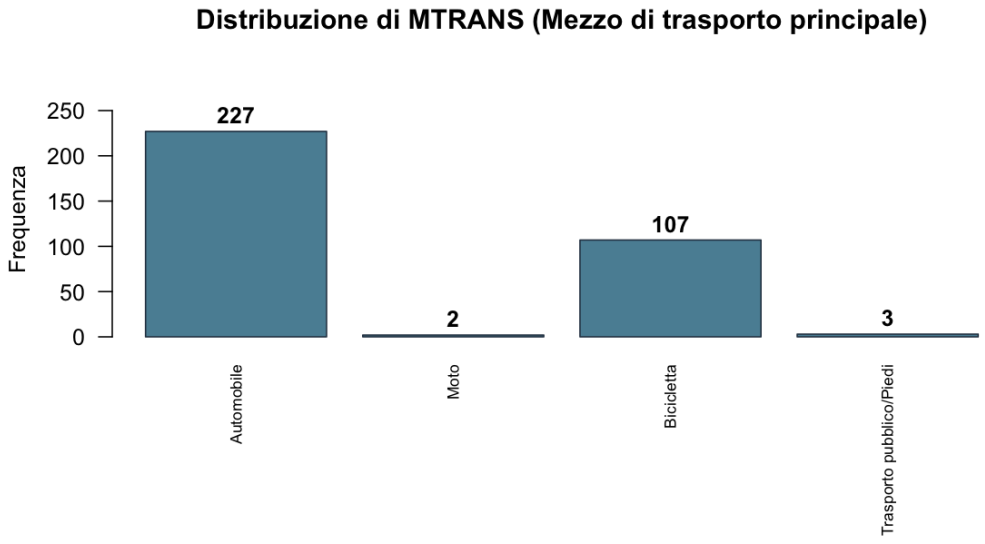

Figura 12: Distribuzione di `MTRANS`

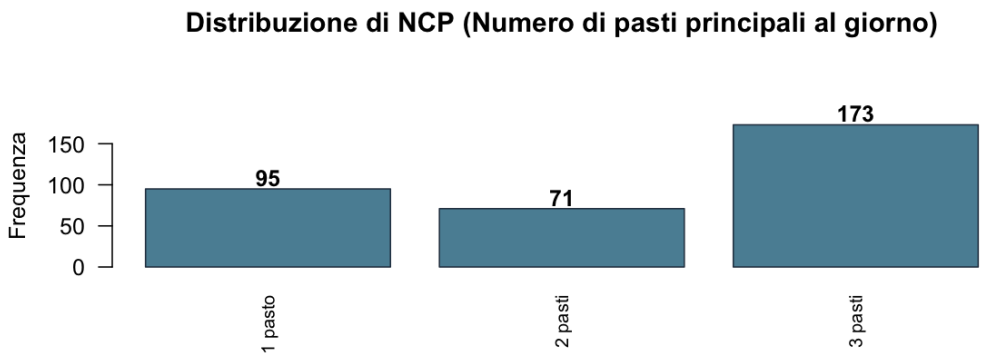

Figura 13: Distribuzione di `NCP`

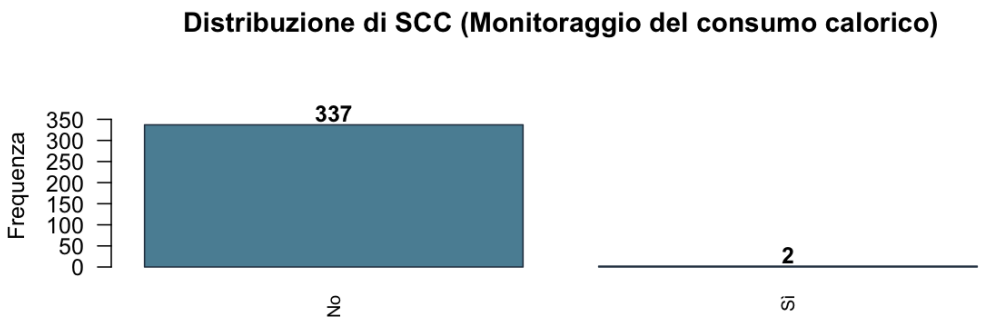

Figura 14: Distribuzione di `SCC`

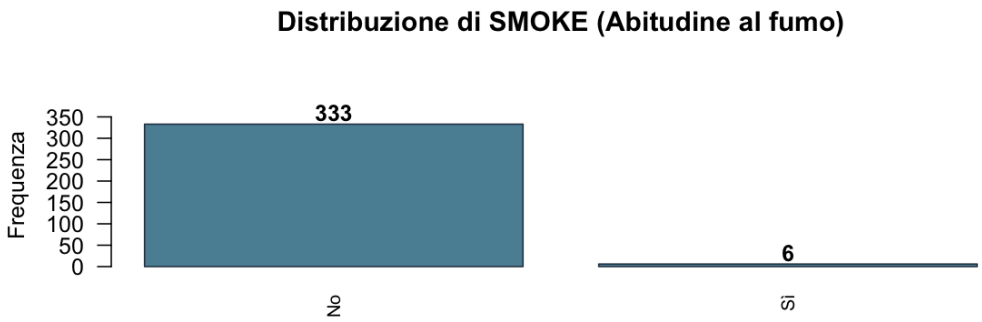

Figura 15: Distribuzione di `SMOKE`

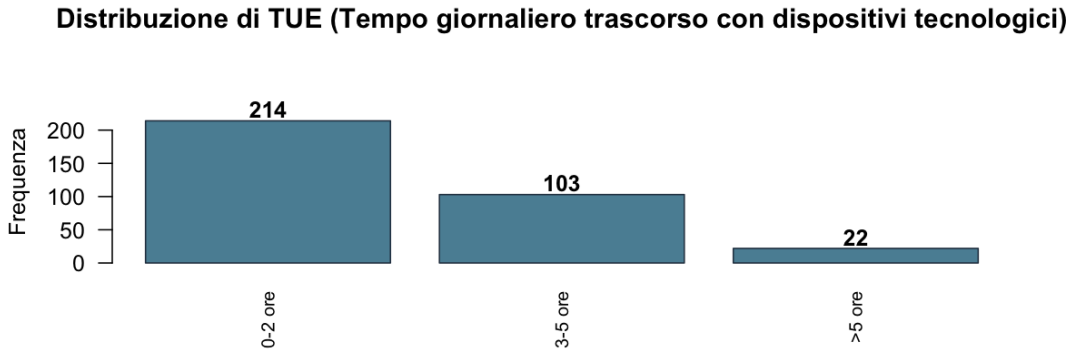

Figura 16: Distribuzione di `TUE`

Sintesi generale delle distribuzioni. Nel campione analizzato ($n = 339$) l'età risulta concentrata sulle classi più giovani e presenta una chiara asimmetria a destra, con alcuni valori estremi nelle età più elevate. L'altezza mostra invece una distribuzione più regolare e unimodale, senza evidenti anomalie, mentre il peso appare più disperso e con una coda verso valori maggiori.

Per le variabili categoriche si osservano diversi sbilanciamenti: il genere è abbastanza bilanciato con una lieve prevalenza di maschi. Il mezzo di trasporto principale è in larga parte l'automobile, mentre le altre modalità risultano poco rappresentate. Il numero di pasti principali tende a concentrarsi su tre pasti al giorno e il tempo giornaliero con dispositivi tecnologici è più frequentemente nelle classi più basse. Sul fronte delle abitudini, il consumo di verdure è prevalentemente riportato come "a volte" e il consumo frequente di cibi ad alto contenuto calorico risulta molto comune. L'acqua bevuta al giorno si concentra nella classe intermedia (1–2L) e la frequenza di attività fisica settimanale è più spesso bassa o assente. Il consumo di alcol è principalmente tra "mai" e "a volte", mentre il consumo di cibo tra i pasti è quasi totalmente indicato come "a volte". Infine, la presenza di casi di sovrappeso in famiglia risulta quasi sempre dichiarata.

4.2 Dipendenze tra variabili

Dopo l'analisi univariata, si indagano le relazioni tra coppie di variabili per individuare pattern, associazioni o ridondanze informative. Per le variabili numeriche si analizza la correlazione lineare (indice di Pearson) visualizzata tramite matrice di correlazione (heatmap) e scatterplot per le coppie più rilevanti. Le relazioni tra variabili categoriche sono esplorate tramite tabelle di contingenza e test di indipendenza (Chi-quadro), supportati da grafici a barre in pila o affiancati. Infine, le relazioni miste (numerica vs categorica) sono visualizzate mediante boxplot stratificati, utili per confrontare le distribuzioni della variabile numerica tra i diversi livelli di quella categorica.

4.2.1 Relazioni tra variabili numeriche

Per valutare l'intensità delle relazioni lineari, si riporta la matrice di correlazione delle variabili quantitative.

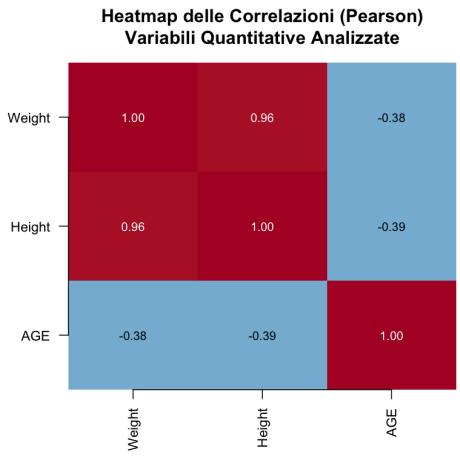

Figura 17: Heatmap della matrice di correlazione di Pearson.

Dall'analisi della heatmap (Fig. 17) emerge chiaramente una fortissima correlazione positiva tra `Weight` e `Height` ($r = 0.96$). Questo valore, molto prossimo a 1, indica che all'aumentare della statura corrisponde quasi linearmente un aumento del peso, una relazione attesa e fisiologica nel campione analizzato. Al contrario, la variabile `AGE` mostra correlazioni negative moderate con entrambe le misure antropometriche: $r = -0.38$ con il peso e $r = -0.39$ con l'altezza. Ciò suggerisce che, nel dataset in esame, i soggetti più giovani tendono ad avere valori di peso e altezza leggermente superiori rispetto ai soggetti più anziani, oppure che il campione include una fascia di popolazione giovane-adulta con caratteristiche fisiche specifiche. Questi coefficienti evidenziano come la struttura delle dipendenze lineari sia dominata dal legame peso-altezza, mentre l'età gioca un ruolo secondario e inverso.

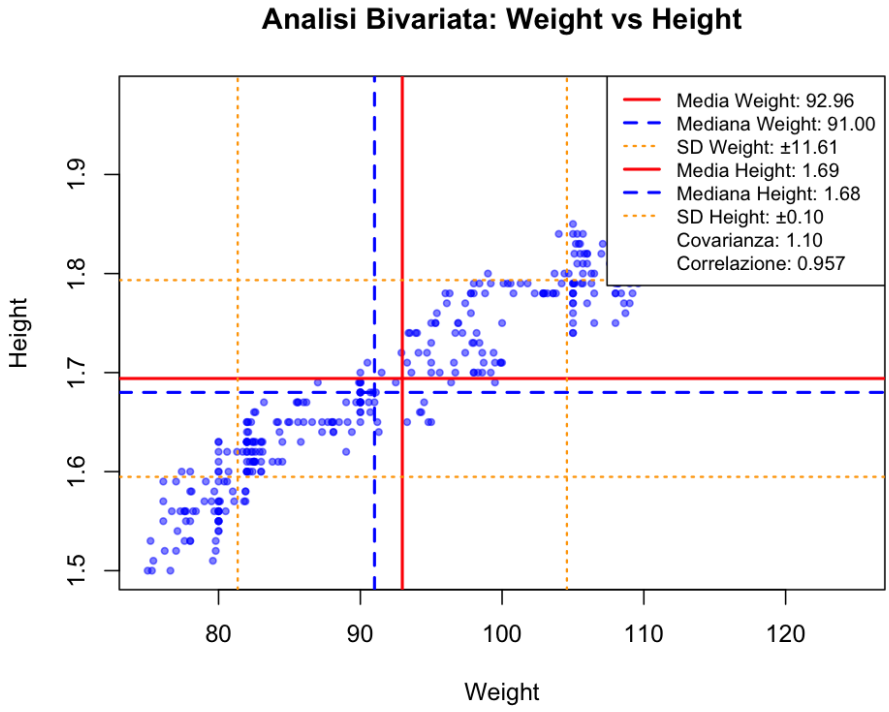

Figura 18: Scatterplot tra Peso e Altezza con indicazione di media (linea continua) e mediana (linea tratteggiata).

Il grafico in Figura 18 conferma visivamente l'elevata correlazione ($r \approx 0.96$). La nuvola dei punti segue un andamento lineare positivo molto netto. Le linee di riferimento mostrano che il baricentro della distribuzione si colloca intorno a 1.70 m per l'altezza e 92 kg per il peso. La vicinanza tra media e mediana suggerisce una certa simmetria centrale, sebbene si osservi una lieve dispersione maggiore per valori elevati di peso, indicando che la variabilità del peso tende ad aumentare nei soggetti più alti.

4.2.2 Relazioni tra variabili categoriche

Le associazioni tra variabili categoriche sono state indagate visualizzando la distribuzione delle frequenze relative condizionate tramite grafici a barre raggruppate (grouped barplot). Questa rappresentazione permette di confrontare direttamente come varia la probabilità di osservare una certa modalità (es. il mezzo di trasporto) al mutare dei livelli della variabile condizionante (es. le abitudini alimentari), rendendo immediatamente visibili eventuali differenze di distribuzione tra i gruppi. Dato l'elevato numero di possibili combinazioni, non vengono riportate tutte le interazioni esplorate, bensì è stata operata una selezione ragionata: nel seguito si presentano solo le relazioni che hanno mostrato pattern evidenti o associazioni potenzialmente rilevanti sul piano interpretativo, basandosi sulla natura delle variabili e sui risultati dell'analisi visiva. Per una panoramica complessiva delle associazioni (heatmap), si rimanda alla Sezione 5.1 e alla Figura 26, dove tali risultati vengono discussi nel contesto dell'analisi di utilità delle feature.

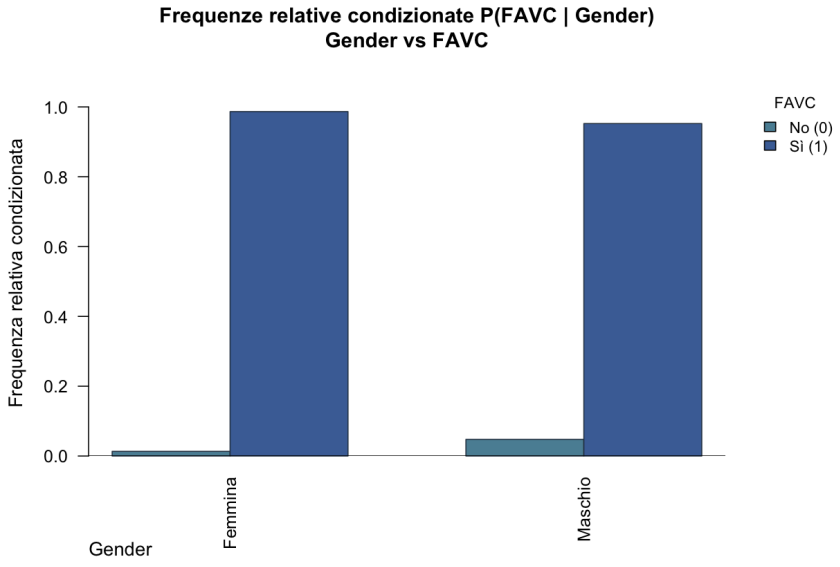

Figura 19: Frequenze relative condizionate del consumo frequente di cibi ipercalorici (`FAVC`) suddivise per genere (`Gender`).

Dall'analisi delle frequenze condizionate (Fig. 19) emerge che il consumo frequente di cibi ad alto contenuto calorico (`FAVC`) è un comportamento predominante nell'intero campione, indipendentemente dal genere. Sia per il genere femminile che per quello maschile, la barra relativa alla risposta "Sì" supera abbondantemente il 90%, indicando che quasi la totalità degli individui osservati adotta un regime alimentare ricco di calorie. Tuttavia, si nota una lievissima differenza nella distribuzione: la proporzione di maschi che non consumano cibi ipercalorici (barra "No") appare leggermente superiore rispetto alla controparte femminile, suggerendo una tendenza quasi universale al consumo calorico nelle donne di questo dataset. Questa omogeneità comportamentale conferma che l'alta densità calorica della dieta è una caratteristica trasversale e distintiva del cluster di obesità analizzato, più che un fattore discriminante tra i sessi.

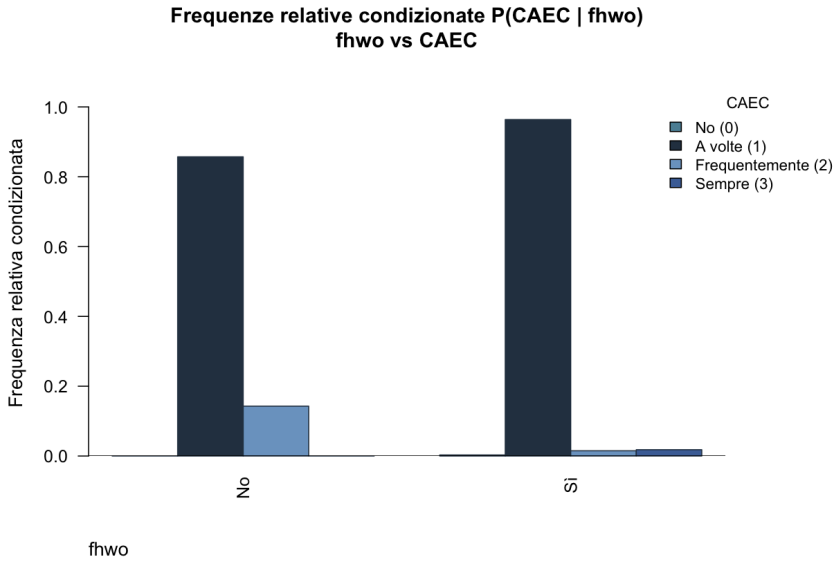

Figura 20: Frequenze relative condizionate del consumo di cibo fuori pasto (`CAEC`) dato la familiarità con l'obesità (`fhwo`).

L'analisi dell'influenza familiare sulle abitudini di "snacking" (Fig. 20) rivela un pattern comportamentale complesso. In entrambi i gruppi (con e senza familiarità per sovrappeso), la modalità predominante è "A volte" (barra blu scuro), che copre la grande maggioranza del campione, indicando che il consumo occasionale di cibo fuori pasto è la norma sociale diffusa. Tuttavia, confrontando le code della distribuzione, si nota che nel gruppo con familiarità (`Sì`) la frequenza di chi dichiara di mangiare "Sempre" fuori pasto (livello 3) appare visivamente presente, seppur minoritaria, mentre è quasi assente nel gruppo senza familiarità. Allo stesso modo, la categoria "No" (livello 0, non mangia mai fuori pasto) sembra avere un peso relativo leggermente maggiore nel gruppo senza familiarità. Sebbene non si osservi un'inversione drastica delle abitudini, questo dato suggerisce che la predisposizione familiare all'obesità possa associarsi a una minore regolazione degli spuntini, spostando lievemente la distribuzione verso frequenze di consumo più elevate.

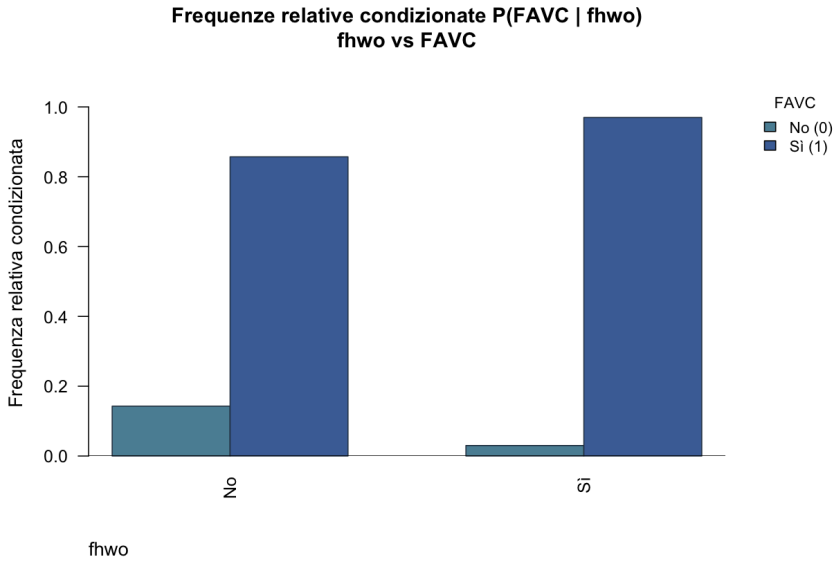

Figura 21: Frequenze relative condizionate del consumo di cibi ipercalorici (`FAVC`) dato la familiarità con l'obesità (`fhwo`).

L'analisi dell'interazione tra predisposizione familiare (`fhwo`) e abitudini alimentari caloriche (`FAVC`) evidenzia un legame estremamente marcato (Fig. 21). Nel gruppo con familiarità per sovrappeso, il consumo frequente di cibi ipercalorici appare pressoché ubiquitario: la barra relativa alla risposta "Sì" (colore blu scuro) sfiora il 100%, indicando che quasi la totalità dei soggetti con background familiare obeso adotta una dieta ad alta densità energetica. Al contrario, nel gruppo senza familiarità, pur rimanendo prevalente il consumo calorico, emerge una quota significativa di individui (barra azzurra "No") che dichiara di non consumare frequentemente tali cibi. Questa discrepanza suggerisce che la familiarità non agisca solo come fattore genetico metabolico, ma sia fortemente correlata alla trasmissione di abitudini alimentari meno salutari ("ereditarietà delle abitudini"), creando un ambiente obesogenico che normalizza l'assunzione di cibi ipercalorici.

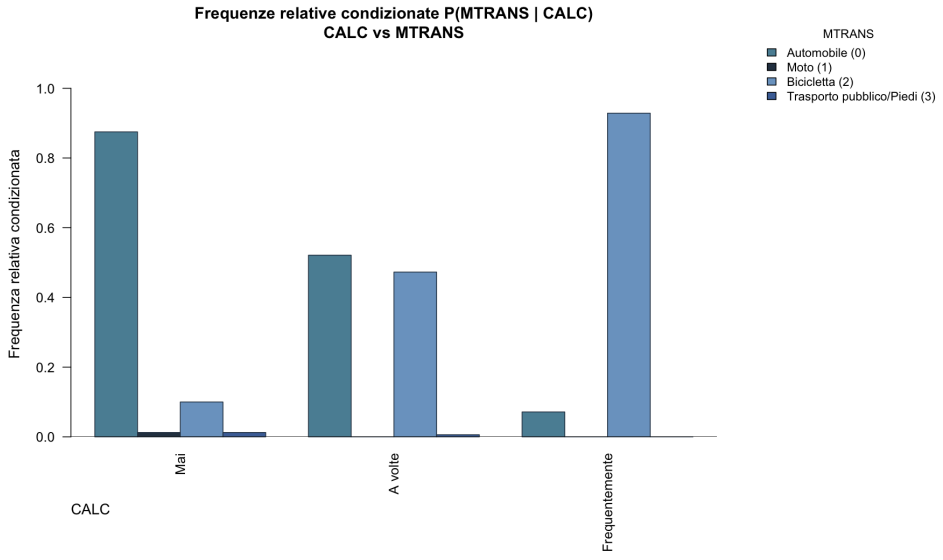

Figura 22: Frequenze relative condizionate del mezzo di trasporto (`MTRANS`) rispetto alla frequenza di consumo di alcol (`CALC`).

L'analisi dell'interazione tra consumo di alcol e mobilità (Fig. 22) mostra pattern di trasporto radicalmente diversi in base alle abitudini voluttuarie. Si osserva una forte polarizzazione: il gruppo che dichiara di bere "Frequentemente" mostra una preferenza quasi esclusiva per una specifica modalità di trasporto (Bicicletta), dissociandosi nettamente dalle abitudini degli astemi (`Mai`). In particolare, chi non consuma mai alcol tende a utilizzare prevalentemente l'automobile, un comportamento che potrebbe riflettere uno stile di vita più sedentario o convenzionale, spesso associato a profili di rischio metabolico diversi. Al contrario, il consumo frequente di alcol sembra associarsi all'uso di mezzi alternativi, un dato che potrebbe indicare una maggiore vita sociale urbana o una scelta consapevole legata alla sicurezza stradale (evitare la guida).

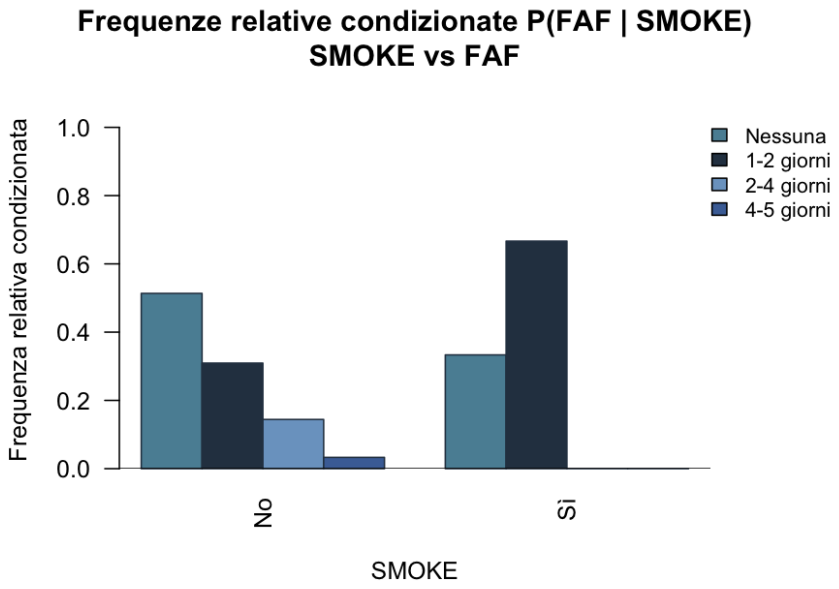

Figura 23: Frequenze relative condizionate della frequenza di attività fisica (`FAF`) rispetto all'abitudine al fumo (`SMOKE`).

L'analisi del rapporto tra fumo e attività fisica (Fig. 23) evidenzia un pattern distintivo nella distribuzione dell'esercizio fisico. Nel gruppo dei non fumatori (`No`), si osserva una distribuzione decrescente "fisiologica": sebbene la sedentarietà (livello 0) sia la modalità più frequente, esiste una quota rilevante di soggetti che pratica attività fisica moderata o intensa (barre a destra). Tra i fumatori (`Sì`), invece, la distribuzione appare più compressa verso il basso. Sebbene emerga un picco anomalo nella categoria di attività leggera (1-2 giorni), è evidente la quasi totale assenza di soggetti che praticano attività fisica frequente o intensa (le barre relative a 2-4 o 4-5 giorni sono trascurabili). Questo suggerisce che il fumo nel campione analizzato agisce come un "limitatore" comportamentale o fisiologico: chi fuma tende a non superare una soglia minima di attività fisica, mentre i non fumatori mostrano uno spettro di stili di vita più ampio, che include anche l'atletismo.

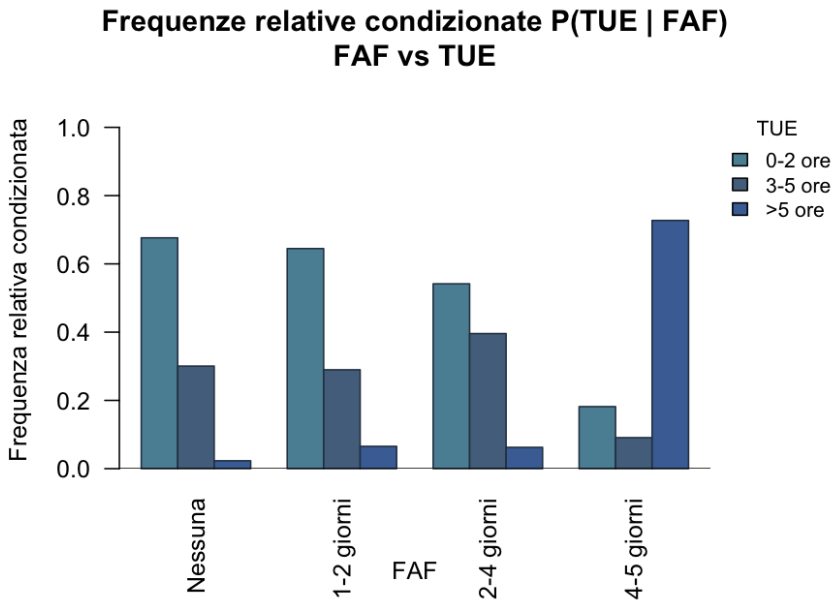

Figura 24: Frequenze relative condizionate dell'uso di dispositivi tecnologici (`TUE`) rispetto alla frequenza di attività fisica (`FAF`).

Infine, l'esplorazione della relazione tra tempo trascorso con dispositivi tecnologici (`TUE`) e frequenza di attività fisica (`FAF`) rivela un pattern inatteso e controintuitivo (Fig. 24). Invece di osservare una correlazione negativa lineare (dove a maggiore uso di tecnologia corrisponde minore sport), si nota che il gruppo con la frequenza di attività fisica più alta (4-5 giorni a settimana) presenta paradossalmente anche la quota più elevata di utilizzo intensivo della tecnologia (barra blu scuro ">5 ore" dominante). Al contrario, i soggetti sedentari o con attività fisica moderata mostrano profili tecnologici più bilanciati o tendenti a un uso basso/medio. Questo fenomeno potrebbe essere spiegato da fattori demografici latenti, in particolare l'età: è plausibile che i soggetti più giovani del campione siano contemporaneamente i più attivi fisicamente e i più forti utilizzatori di dispositivi digitali, dissociando di fatto l'uso della tecnologia dalla sedentarietà automatica in questo specifico cluster.

4.3 Anomalie, bias e limitazioni osservate

L'analisi esplorativa condotta (EDA) ha portato alla luce alcune criticità strutturali e semantiche nel dataset che potrebbero influenzare le successive fasi di modellazione. In questa sezione si discutono le principali anomalie numeriche, i bias di autoselezione e le limitazioni interpretative delle variabili categoriche.

4.3.1 Artefatti numerici e generazione sintetica (SMOTE)

Un'analisi della distribuzione delle variabili continue (in particolare `AGE`) ha evidenziato la presenza sistematica di valori decimali atipici per dati anagrafici. Come confermato dalla documentazione originale [[2]], questo fenomeno non è dovuto a errori di misurazione, ma è una conseguenza diretta della tecnica di Data Augmentation utilizzata: il **SMOTE** (Synthetic Minority Over-sampling Technique). Gli autori dichiarano che solo il 23% dei dati proviene da individui reali, mentre il restante **77% è stato generato sinteticamente**. L'algoritmo crea nuovi record interpolando tra vettori esistenti, generando così valori come "23.45 anni" che, pur matematicamente validi, introducono un rumore artificiale rispetto alla natura discreta delle

variabili reali. La Figura 25 visualizza chiaramente questo artefatto, mostrando la discrepanza tra i picchi naturali (interi) e il rumore sintetico (decimali).

Confronto Arrotondamento: AGE
(Arrotondamento a 0 decimali - 258 valori modificati su 351, 73.50%)

Statistica	Prima	Dopo	Differenza
Media	25.884941	25.903134	0.018193
Deviazione Standard	7.755700	7.772976	0.017277
Mediana	22.975526	23.000000	0.024474
IQR (Q3-Q1)	8.905919	9.000000	0.094081
Min	15.000000	15.000000	0.000000
Max	52.000000	52.000000	0.000000

Figura 25: Confronto tra valori interi e decimali nella variabile Età (`AGE`), evidenziando la presenza di artefatti numerici dovuti alla generazione sintetica dei dati.

4.3.2 Squilibrio nelle classi categoriche (Class Imbalance)

Nelle variabili categoriche comportamentali, in particolare `CAEC` (Consumo di cibo fuori pasto) e `CALC` (Consumo di alcol), si osserva una dominanza schiacciante della categoria intermedia "A volte" (*Sometimes*). Questa concentrazione di frequenze (spesso superiore all'80% del campione per `CAEC`) comporta un appiattimento dell'informazione (*information flattening*): la variabile perde capacità discriminante, rendendo difficile per il modello separare i profili di rischio basandosi solo su questi feature, a meno di non ricorrere a comportamenti estremi ("Sempre" o "Mai") che sono però numericamente rari.

4.3.3 Bias demografico e culturale

L'analisi delle correlazioni ha fatto emergere pattern che suggeriscono forti bias nel campionamento:

- **Bias Giovanile (Age Bias):** La correlazione positiva inattesa tra alto uso di tecnologia (`TUE` $>$ 5 ore) e frequente attività fisica (`FAF`) suggerisce che il campione sia sbilanciato verso una popolazione giovane (studenti/universitari). In particolare, la distribuzione di `AGE`, rappresentata in figura 1, conferma un profilo prevalentemente giovanile: mediana pari a 23 anni e media pari a 25.96 (n = 339), con valori concentrati nelle età più basse e una coda verso età maggiori (fino a 52 anni). In questa coorte, l'uso del PC non è necessariamente sinonimo di sedentarietà passiva (come può accadere in fasce d'età più avanzate), ma spesso è legato a studio o lavoro e può risultare compatibile con uno stile di vita attivo.
- **Limitazioni Geografiche:** Il dataset copre una popolazione dell'area latinoamericana (Messico, Perù, Colombia). Variabili come il trasporto pubblico (`MTRANS`) o le abitudini ali-

mentari risentono del contesto infrastrutturale e culturale locale, limitando la trasferibilità diretta dei risultati a contesti europei.

4.3.4 Appiattimento informativo e variabili Proxy

Si segnalano infine due criticità semantiche:

1. **Dominanza della classe modale:** Variabili come `CAEC` (cibo fuori pasto) presentano una concentrazione eccessiva di risposte nella categoria "A volte" (>80%), riducendo il potere discriminante della feature (*Information Flattening*).

2. **Effetto Proxy:** Alcune variabili misurano costrutti diversi da quelli apparenti. Ad esempio, il consumo di alcol (`CALC`) nel dataset sembra agire più come proxy di "socialità giovanile" (correlato a mobilità e uscite) che come mero fattore nutrizionale negativo, complicando l'interpretazione causale.

4.3.5 Limiti del Self-Reporting

Infine, trattandosi di dati derivanti da questionari, permane il rischio di *Social Desirability Bias*. Tuttavia, le incongruenze rilevate (es. fumatori che dichiarano attività fisica moderata ma nulla intensa) suggeriscono che più che una falsificazione intenzionale, vi sia una soggettività nell'interpretazione delle domande (es. cosa costituisce "attività fisica"), che il modello dovrà gestire come incertezza intrinseca.

5 Analisi dell'utilità delle feature

5.1 Criteri di utilità e metodologie adottate

Al fine di determinare quali variabili apportino un reale contributo informativo e quali rappresentino invece ridondanza o rumore, è stato adottato un approccio analitico multiprospettico. L'utilità delle feature non è stata valutata sulla base di un singolo indicatore, bensì attraverso la convergenza di quattro metodologie statistiche distinte:

1. **Analisi delle Correlazioni (Pearson e Spearman):** È stata esaminata la matrice di correlazione per individuare fenomeni di collinearità. Le feature con coefficienti di correlazione prossimi a 1 (o -1) sono state segnalate come ridondanti, in quanto apportano la medesima informazione. L'obiettivo è mantenere solo le variabili che offrono contributi informativi il più possibile ortogonali (non ridondanti).

2. **Analisi di Pareto (Variabilità Cumulata):** Applicando il principio di Pareto (regola 80/20) alla varianza delle feature normalizzate, abbiamo identificato le "vital few" rispetto alle "useful many". Questo passaggio ha permesso di isolare il sottoinsieme di variabili che, da sole, spiegano la maggior parte della variabilità intrinseca del dataset, scartando quelle con varianza trascurabile (costanti o quasi costanti).

3. **Potere Discriminante nel Clustering (K-Means Profiling):** È stata effettuata un'analisi di clustering non supervisionata (algoritmo K-Means) per verificare la tendenza naturale dei dati a raggrupparsi. L'utilità delle feature è stata misurata *a posteriori* valutando la loro capacità di discriminare i cluster identificati: variabili con medie diverse tra cluster (alta varianza *Between* rispetto alla *Within*) sono considerate più caratterizzanti.

4. **Riduzione della complessità (MCA):** Considerata la prevalenza di feature qualitative, la struttura latente del dataset è stata esplorata tramite *Analisi delle Corrispondenze Multiple (MCA)*, tecnica specifica per dati categorici. Le evidenze e l'interpretazione dei grafici diagnostici (scree plot/inertia, contributi delle variabili, mappa delle modalità e degli individui) sono discusse nella Sezione dedicata (Sez. 5.5).

5.2 Analisi dei coefficienti di correlazione

L'analisi delle dipendenze tra le feature è stata condotta separando le variabili in due gruppi distinti in base alla loro natura statistica: variabili qualitative (categoriche) e variabili quantitative (numeriche). Questo approccio ha permesso di utilizzare le metriche di associazione più appropriate per ciascun tipo di dato.

5.2.1 Analisi delle variabili qualitative (Cramér's V)

Per valutare l'associazione tra le feature categoriche, è stato calcolato l'indice **V di Cramér**, una misura normalizzata del Chi-Quadro che varia da 0 (nessuna associazione) a 1 (associazione perfetta).

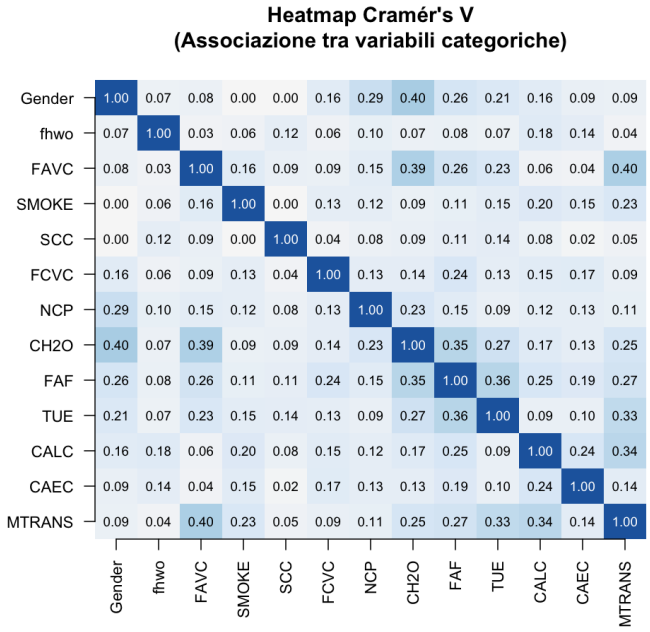

Figura 26: Matrice di associazione (Heatmap) basata sull'indice V di Cramér per le variabili categoriche. I valori indicano l'intensità della relazione (0=nulla, 1=perfetta).

Osservando la heatmap delle associazioni emergono i seguenti risultati:

- **Assenza di Ridondanza Critica:** Non si osservano valori prossimi a 1 tra le variabili esplicative. Il valore massimo riscontrato è 0.40, il che indica che non vi è una forte collinearità tra le feature categoriche. Ogni variabile apporta, quindi, un contributo informativo relativamente unico.
- **Associazioni Rilevanti:** Le relazioni più significative ($V \geq 0.35$) riguardano:
  - **Gender vs CH2O (0.40):** Indica una differenza moderata nelle abitudini di consumo d'acqua tra uomini e donne.
  - **MTRANS vs FAVC (0.40):** Suggerisce un legame tra il mezzo di trasporto utilizzato e il consumo frequente di cibi ad alto contenuto calorico (es. chi usa l'auto potrebbe tendere a abitudini alimentari diverse rispetto a chi cammina).
  - **CH2O vs FAVC (0.39):** Mostra una moderata associazione tra consumo d'acqua e consumo frequente di cibi ad alto contenuto calorico, suggerendo che le abitudini alimentari possono andare di pari passo con differenti pattern di idratazione (ad es. preferenza per bevande diverse dall'acqua nei soggetti con dieta più "calorica").
  - **FAF vs TUE (0.36):** Esiste una moderata associazione tra l'attività fisica (FAF) e il tempo speso con dispositivi tecnologici (TUE), confermando che stili di vita sedentari e attivi tendono ad escludersi a vicenda o a seguire pattern inversi.
  - **CH2O vs FAF (0.35):** Indica un legame debole–moderato tra idratazione e attività fisica: chi svolge più attività fisica potrebbe tendere a bere più acqua, ma l'associazione non è forte e può dipendere anche da altri fattori (routine quotidiana, clima, abitudini personali).

In conclusione, le variabili categoriche presentano una struttura di dipendenza debole-moderata.

5.2.2 Analisi delle variabili quantitative

Per le variabili numeriche (*Age*, *Height*, *Weight*), l'analisi della correlazione di Pearson ha evidenziato una criticità strutturale fondamentale per il dominio del problema:

- **La correlazione Peso-Altezza:** Come atteso in qualsiasi dataset antropometrico, esiste una correlazione positiva naturale tra *Height* (Altezza) e *Weight* (Peso). Tuttavia, l'uso simultaneo di queste due variabili grezze può introdurre rumore o ridondanza nei modelli lineari.

- **Il limite delle variabili grezze:** Sebbene il peso sia il predittore singolo più forte per l'obesità, esso non è normalizzato per la costituzione fisica. Un peso elevato può indicare obesità in un soggetto basso, ma essere normopeso in un soggetto molto alto. Di conseguenza, la relazione tra *Weight* e il target *Obesity* non è perfettamente lineare ma condizionata dall'*Height*.

- **Necessità di una feature sintetica (BMI):** La forte correlazione positiva riscontrata tra *Weight* e *Height* suggerisce che queste due grandezze non dovrebbero essere trattate come predittori indipendenti nei modelli lineari, per evitare problemi di multicollinearità. È metodologicamente preferibile sintetizzarle nella variabile derivata **Body Mass Index (BMI)**, calcolata come:

  $$BMI = \frac{Weight(kg)}{Height(m)^2}$$

  Tale indice cattura la relazione non lineare tra massa e statura, allineandosi alle definizioni mediche standard e massimizzando il contenuto informativo rispetto all'uso disgiunto delle componenti.

- **Identificazione della Classe Target e Analisi delle Anomalie:** La ricostruzione puntuale del BMI ha svolto un ruolo investigativo cruciale. Analizzando la distribuzione dei valori calcolati è emerso che la densità di probabilità è quasi interamente concentrata nell'intervallo $[30.0, 34.9]$. Questo riscontro empirico ha permesso di confermare la natura del dataset come sottoinsieme specifico della classe clinica **Obesity_Type_I**.

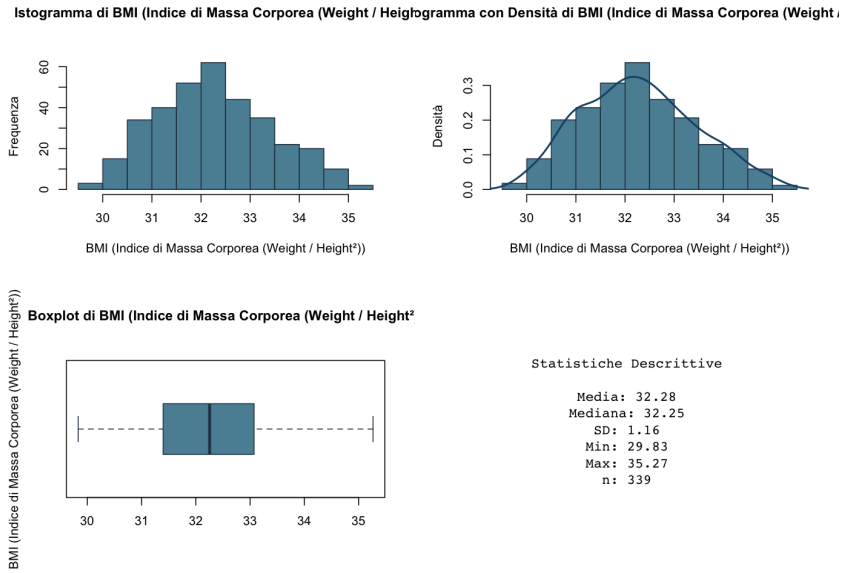

Figura 27: Analisi distributiva del Body Mass Index (BMI) ricalcolato. I grafici (Istogramma, KDE, Boxplot) e le statistiche descrittive confermano l'appartenenza del campione alla classe Obesity Type I, pur evidenziando lievi sconfinamenti ai margini dovuti agli artefatti di generazione sintetica (SMOTE).

Tuttavia, l'analisi descrittiva ha evidenziato la presenza di 6 osservazioni marginalmente anomale ("out-of-range"), con valori estremi di 29.83 (sovrappeso) e 35.27 (obesità II). Tali deviazioni non sono attribuibili a errori di misurazione, bensì sono artefatti computazionali derivanti dalla tecnica di sovracampionamento sintetico (**SMOTE**) utilizzata nella costruzione del dataset originale. L'interpolazione lineare tra vettori nello spazio delle feature ha generato combinazioni di peso/altezza che, pur appartenendo statisticamente al cluster degli obesi, sconfinano matematicamente dalle soglie rigide della classificazione **WHO** (World Health Organization).

5.3 Analisi di Pareto (Variabilità delle feature)

Per quantificare il contenuto informativo delle variabili qualitative, si è fatto ricorso all'analisi dell'**Entropia di Shannon** anziché alla varianza classica. L'entropia (H) misura il grado di "disordine" o imprevedibilità di una variabile: una feature con entropia elevata presenta una distribuzione delle classi eterogenea (molta informazione), mentre una feature con entropia prossima allo zero è sostanzialmente costante (poca informazione).

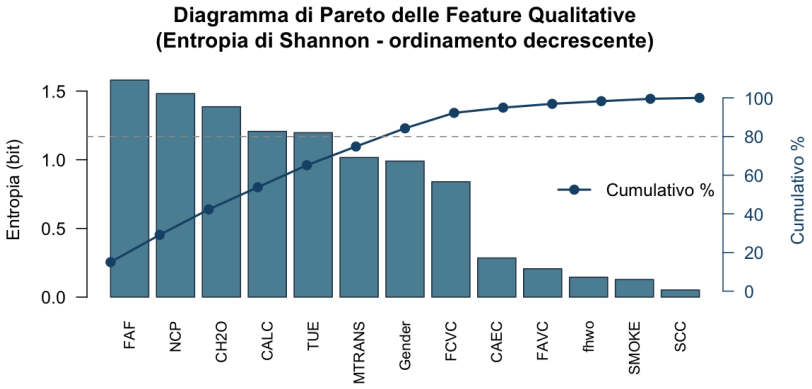

Figura 28: Diagramma di Pareto basato sull'Entropia di Shannon per le feature categoriche. Le barre indicano la quantità di informazione (in bit) contenuta in ciascuna variabile. Le variabili a sinistra (FAF, NCP) mostrano la maggiore variabilità distributiva, mentre quelle a destra (SMOKE, SCC) sono quasi costanti e poco informative.

Il diagramma di Pareto ordina le feature in base al loro contenuto informativo (bit). Dall'analisi della curva cumulata emergono tre fasce di utilità:

- **High Information Density (Vital Few):** Le variabili **FAF** (Attività fisica), **NCP** (Numero pasti) e **CH2O** (Consumo acqua) mostrano i livelli di entropia più alti (> 1.4 bit). Ciò indica che il campione è estremamente variegato rispetto a queste abitudini: non esiste un comportamento standard, ma una ricca distribuzione di frequenze che rende queste variabili ottimi descrittori della diversità individuale. Inoltre, la combinazione di queste feature con **CALC** e **TUE** cattura, da sola, circa l'80% dell'informazione complessiva (in termini di variabilità spiegata).
- **Balanced Features:** Variabili come *Gender* presentano un'entropia vicina a 1 bit. Essendo una variabile binaria, questo è il valore massimo teorico raggiungibile, confermando che il dataset è quasi bilanciato tra maschi e femmine, privo di bias di campionamento sul genere.
- **Low Information Density (Useful Many):** Nella coda della distribuzione troviamo **SMOKE** e **SCC** con entropia prossima allo zero. Questo risultato segnala che tali comportamenti sono estremamente rari o uniformi nel campione (es. quasi nessuno fuma). Ai fini dell'analisi statistica, queste variabili apportano un contributo informativo marginale e potrebbero essere escluse senza significativa perdita di potere descrittivo.

L'analisi conferma che la "personalità statistica" dei soggetti è definita molto più dalle abitudini quotidiane (sport, acqua, pasti) che non da vizi specifici come il fumo, che risultano statisticamente trascurabili.

5.4 Potere discriminante del Clustering (K-Means)

Per valutare l'importanza relativa delle feature categoriche nella definizione dei profili naturali dei soggetti, è stato calcolato il rapporto tra la varianza *Between-Cluster* (dispersione tra i gruppi) e la varianza *Within-Cluster* (dispersione interna ai gruppi). Un rapporto elevato indica che la variabile caratterizza in modo netto i diversi cluster identificati dall'algoritmo K-Means.

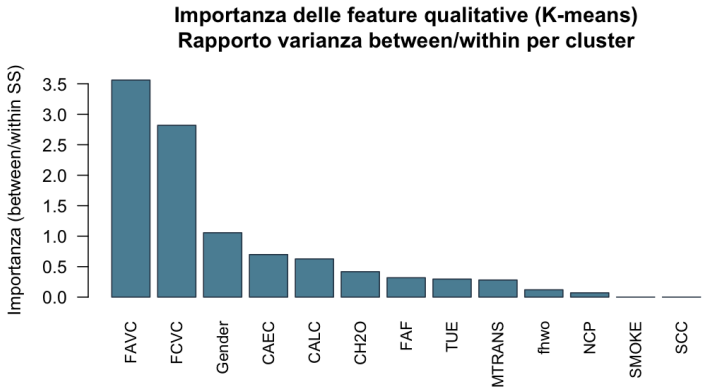

Figura 29: Classifica dell'importanza delle feature categoriche basata sul clustering K-Means. Le barre rappresentano il rapporto tra varianza "Between" (tra i cluster) e "Within" (interna), indicando quanto nettamente ogni variabile separa i gruppi identificati. Si nota la netta predominanza delle abitudini alimentari (FAVC, FCVC) rispetto ad altre caratteristiche.

Come evidenziato nel grafico, l'analisi restituisce una gerarchia di utilità molto chiara:

- **Dominanza Strutturale di FAVC e FCVC:** Mentre l'analisi di Pareto (Sez. 5.3) identificava *FAF* e *NCP* come le variabili a maggiore contenuto entropico (più variegate), l'analisi dei cluster elegge **FAVC** (Cibi calorici) e **FCVC** (Verdure) come discriminanti strutturali del dataset (ratio > 2.5).
- **Interpretazione del confronto:** Questa discrepanza suggerisce che, sebbene le abitudini di attività fisica (*FAF*) siano molto eterogenee tra gli individui (alta entropia), non sono loro a definire i "confini" principali dei gruppi. I gruppi naturali si formano primariamente sulla base della dieta. In altri termini: l'attività fisica è una sfumatura individuale, ma la dieta è il fattore che classifica le persone.
- **Conferma sulle variabili irrilevanti:** Vi è invece perfetta concordanza riguardo le feature *SMOKE* e *SCC*: classificate come "povere di informazione" dall'entropia di Pareto, si confermano incapaci di discriminare i cluster nell'analisi K-Means. Questo doppio riscontro ne sancisce la definitiva irrilevanza statistica nel contesto di questo studio.

In conclusione, l'analisi incrociata rivela che l'eterogeneità "caotica" (misurata dall'entropia) è guidata dallo sport e dai pasti, ma la struttura "ordinata" (i cluster) è dettata dalla qualità del cibo ingerito.

5.5 Riduzione della complessità tramite MCA

Poiché la maggior parte delle feature del dataset è di natura qualitativa (categorica), l'analisi della struttura latente è stata condotta mediante l'**Analisi delle Corrispondenze Multiple (MCA)**, tecnica elettiva per individuare pattern geometrici in dati nominali.

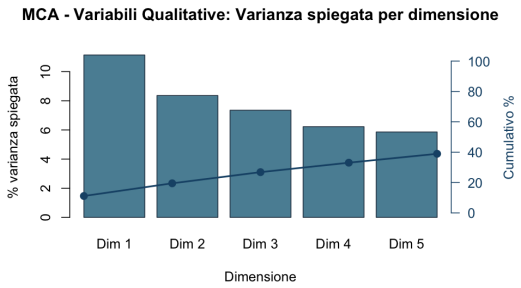

(a) Scree Plot della varianza spiegata: le prime dimensioni catturano la struttura principale.

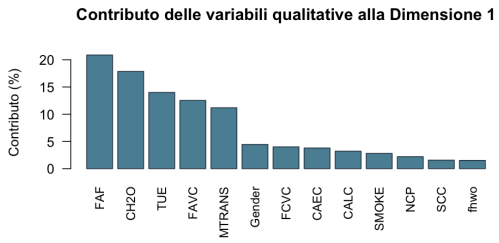

(b) Contributo delle variabili alla Dimensione 1: FAF, CH2O e TUE sono le determinanti principali.

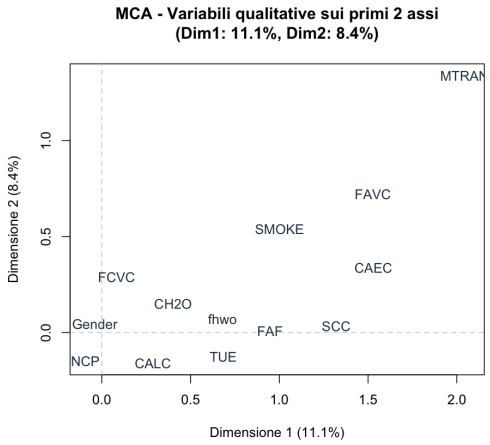

(c) Mappa delle variabili: visualizza le associazioni tra categorie (punti vicini = categorie associate).

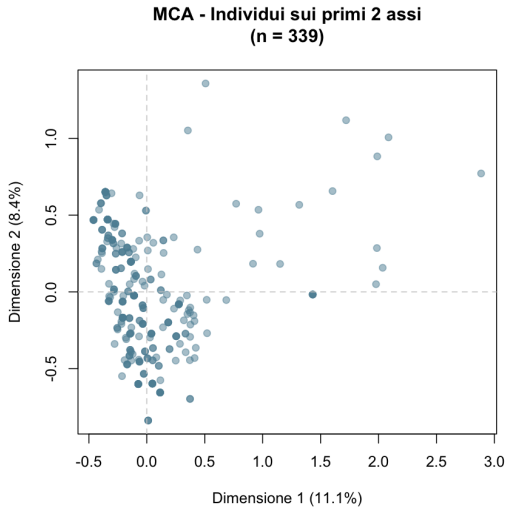

(d) Mappa degli individui: distribuzione dei soggetti nello spazio ridotto.

Figura 30: Analisi delle Corrispondenze Multiple (MCA).

L'analisi dei grafici diagnostici restituisce il seguente quadro strutturale:

- **Gerarchia delle Dimensioni Latenti (Scree Plot):** Il grafico della varianza spiegata mostra che l'informazione non è concentrata in una singola dimensione dominante, ma distribuita. Le prime due dimensioni spiegano congiuntamente circa il **20%** dell'inerzia totale. Sebbene apparentemente basso, tale valore è tipico nell'MCA (dove ogni livello di ogni categoria aumenta la dimensionalità) e indica comunque la presenza di una struttura non casuale.

- **I "Driver" della Dimensione 1 (Contributi):** L'analisi dei contributi rivela che la prima dimensione (l'asse principale di differenziazione tra i soggetti) è definita quasi esclusivamente dalle abitudini quotidiane: **FAF** (Attività Fisica), **CH2O** (Consumo Acqua) e **TUE** (Uso Tecnologia) sono le feature con il peso maggiore ($> 15\%$). Curiosamente, variabili strutturali come il Genere o abitudini come il Fumo hanno un ruolo secondario su questo asse principale. *Interpretazione:* L'asse 1 può essere etichettato come l'asse dello **"Stile di Vita Dinamico"**.

- **Mappa delle Associazioni (Variables Plot):** La proiezione delle variabili nel piano fattoriale evidenzia cluster di comportamenti associati. Si nota una prossimità tra **Gender**, **NCP** e **FCVC** nel quadrante in basso a sinistra, suggerendo che queste caratteristiche tendono a covariare. Al contrario, **MTRANS** (Mezzi di trasporto) e **FAVC** (Cibi calorici) si proiettano in direzioni opposte, indicando che rappresentano dimensioni indipendenti o contrapposte dello spazio comportamentale.

- **Distribuzione dei Soggetti (Individuals Plot):** La nuvola dei punti mostra una tipica forma a "ferro di cavallo" (Effetto Guttman), che suggerisce l'esistenza di un gradiente continuo latente piuttosto che gruppi nettamente separati. La densità dei punti sulla sinistra indica un nucleo omogeneo di soggetti con comportamenti simili, mentre la dispersione verso destra identifica i profili più atipici o estremi.

In sintesi, l'MCA conferma che la complessità del dataset può essere ridotta focalizzandosi sulle variabili di attività (FAF, TUE) e nutrizione (FAVC, CH2O), che costituiscono l'ossatura statistica che differenzia gli individui.

5.6 Costruzione di nuove feature (Feature Engineering)

Sulla base delle evidenze emerse dalle analisi multivariate (MCA e Clustering), è stata implementata una strategia di *Feature Construction* volta a sintetizzare le variabili originali in tre macro-indicatori latenti. L'obiettivo è ridurre la dimensionalità preservando l'informatività semantica.

5.6.1 Diet Quality Index (DQI)

Per aggregare le molteplici variabili nutrizionali in un unico punteggio di qualità (range 0-1), è stato creato un indice ponderato. I pesi (w_i) sono stati assegnati integrando la logica nutrizionale con i valori di "Contributo alla Dimensione 1" emersi dall'MCA (Fig. 30), che identificano *CH2O* e *FAVC* come i driver statistici principali.

Le variabili sono state normalizzate in [0,1] e combinate come segue:

$$DQI = 0.4 \cdot CH2O_n + 0.3 \cdot (1 - FAVC_n) + 0.2 \cdot FCVC_n + 0.1 \cdot (1 - CAEC_n)$$

Dove le variabili negative (Cibi calorici, Snack) sono state invertite $(1 - x)$.

Analisi delle Componenti La validazione interna dell'indice (Fig. 33) conferma che la metrica si comporta in modo coerente con le premesse di costruzione. Si osserva una fortissima correlazione positiva con il consumo d'acqua ($r = 0.91$), identificato dall'MCA come uno dei marker principali di salute, e una correlazione negativa moderata con il consumo di cibi calorici ($r = -0.56$). Il consumo di verdure ($FCVC$) mostra un'associazione positiva ma più debole ($r = 0.39$), suggerendo che nel campione l'idratazione è un discriminante comportamentale più forte dell'apporto vegetale.

Nota Metodologica (Discretizzazione): È opportuno osservare che i pattern regolari ("a griglia") visibili negli scatterplot derivano dalla natura discreta delle variabili di input (ordinali e binarie). Poiché il DQI è una combinazione lineare di un numero finito di stati, l'indice non è propriamente continuo ma assume un insieme discreto di valori possibili, generando la struttura visiva a bande orizzontali osservata.

Distribuzione nel Campione L'istogramma del DQI (Fig. 34) rivela una distribuzione asimmetrica con una media di 0.33 ($\sigma = 0.16$). La grande maggioranza dei soggetti si addensa nella fascia medio-bassa della qualità dietetica, mentre sono rari i profili nutrizionali eccellenti ($DQI > 0.8$). Questo riflette la natura patologica del campione (soggetti obesi), caratterizzato tendenzialmente da abitudini alimentari sub-ottimali.

Relazione con il BMI (Risultato Controintuitivo) Un'analisi fondamentale ha riguardato l'associazione tra la qualità della dieta e la gravità dell'obesità. Contrariamente alle aspettative generali, l'analisi di correlazione (Fig. 35) restituisce un coefficiente di Pearson prossimo allo zero ($r = -0.06$).

Interpretazione: Questo risultato indica che, all'interno dello specifico cluster *Obesity_Type_I*, le variazioni di peso non sono spiegate unicamente dalla qualità della dieta attuale, suggerendo la prevalenza di fattori alternativi.

5.6.2 Activity Index (AI): Analisi dello Stile di Vita

Parallelamente all'aspetto nutrizionale, è stato calcolato l'*Activity Index* (AI) per quantificare il livello di dinamismo complessivo dei soggetti, integrando l'attività sportiva intenzionale (FAF) con la mobilità quotidiana ($MTRANS$) e penalizzando la sedentarietà digitale (TUE).

L'indice è definito come combinazione pesata di variabili normalizzate (FAF_n, TUE_n), più un punteggio di mobilità calcolato a parte:

$$AI = 0.5 \cdot FAF_n + 0.3 \cdot (1 - TUE_n) + 0.2 \cdot MTRANS_{\text{score}}.$$

Per MTRANS si è costruito un punteggio in $[0, 1]$ scalando e *clippando* i valori:

$$MTRANS_{\text{score}} = \min\Big(1,\ \max\big(0, \tfrac{MTRANS}{3}\big)\Big),$$

Validazione e Struttura dell'Indice L'analisi di correlazione tra l'indice aggregato e le sue componenti (Fig. 36) dimostra un bilanciamento efficace dei pesi assegnati. L'indice è guidato primariamente dalla frequenza di attività fisica ($r = 0.68$) e dal tipo di trasporto utilizzato ($r = 0.56$), mentre è inversamente proporzionale al tempo trascorso davanti ai dispositivi ($r = -0.46$). La distribuzione dell'indice nel campione (Fig. 37) presenta una media di 0.40 ($\sigma = 0.17$) e una forma multimodale, che suggerisce l'esistenza di sottogruppi comportamentali distinti (es. "sedentari assoluti" vs "moderatamente attivi") piuttosto che un continuum uniforme.

Relazione con il BMI (Conferma dell'Indipendenza) Analogamente a quanto osservato per la dieta, anche l'analisi dell'attività fisica rivela una sostanziale indipendenza rispetto al

BMI. Il coefficiente di correlazione è nullo ($r = -0.04$) e i boxplot stratificati (Fig. 38) mostrano che il peso corporeo medio rimane costante attraverso i quartili di attività.

Interpretazione Clinica: Il fatto che né la qualità della dieta (DQI) né il livello di attività (AI) correlino con il BMI all'interno della classe *Obesity_Type_I* rafforza l'ipotesi che, in questo stadio patologico, il peso sia mantenuto da meccanismi omeostatici resistenti alle variazioni comportamentali di breve periodo, o che il dataset catturi una "fotografia" statica dove gli effetti benefici dello stile di vita non si sono ancora manifestati sul peso.

6 Generazione e valutazione di dati sintetici

6.1 Scelta del modello LLM e motivazione basata su benchmark

6.1.1 Selezione del modello: GPT-5.2

Per l'esperimento di generazione di dati sintetici, è stato selezionato il modello **GPT-5.2 (variante xhigh)** di OpenAI. La scelta è stata guidata da un'analisi comparativa basata sulla *LLM Leaderboard* di Artificial Analysis [1], facendo riferimento allo stato dell'arte al momento della stesura del presente documento (Febbraio 2026).

Dall'analisi della classifica, che confronta oltre 100 modelli su metriche standardizzate, emergono i fattori determinanti per la selezione:

- **Primato nell'Intelligence Score:** Al momento dell'analisi, GPT-5.2 (xhigh) detiene il punteggio più alto nella metrica di "Intelligence", posizionandosi al vertice della graduatoria globale e superando competitor diretti come Claude Opus 4.5 e Gemini 3 Pro Preview. Tale capacità di ragionamento superiore è ritenuta critica per emulare correttamente le covarianze statistiche non lineari del dataset.

- **Trade-off Accuratezza/Struttura:** Nonostante la disponibilità di modelli con contesti più ampi (es. Llama 4 Scout) o latenze inferiori (es. Gemini 2.5 Flash-Lite), GPT-5.2 è stato preferito per la sua documentata robustezza nel rispetto di vincoli logici complessi e formati di output strutturati, riducendo il rischio di generazione di dati sintatticamente validi ma semanticamente incoerenti.

L'utilizzo di quello che, alla data odierna, rappresenta il benchmark di riferimento per l'intelligenza artificiale generativa, mira a massimizzare la fedeltà statistica dei dati sintetici prodotti.

6.1.2 Strategia di Prompt Engineering

Per sfruttare appieno le capacità di ragionamento di GPT-5.2 e mitigare il rischio di "allucinazioni statistiche" (generazione di valori plausibili ma distributivamente errati), è stata progettata una strategia di prompting strutturata a stadi, definita **"Constraint-Based Contextual Generation"**.

Il prompt inviato al modello non è una semplice richiesta generativa, ma un set di istruzioni tecniche articolato in quattro moduli logici:

1. **Role & Persona Adoption:** Si istruisce il modello ad assumere il ruolo di un *"Data Scientist esperto in simulazione di dati biomedici"*, attivando i pattern latenti relativi alla coerenza fisiologica (es. rapporto peso/altezza).

2. **Schema Definition & Constraints (Hard Rules):** Vengono forniti i metadati rigidi del dataset target:

   - **Elenco Feature:** Nomi esatti delle 17 colonne.
   - **Domini di Variabile:** Per le categoriche, l'elenco tassativo dei livelli ammessi (es. $CALC \in$ {'Mai', 'A volte', 'Sempre'}).
   - **Vincoli Numerici:** Range di validità per età (15-52) e definizione operativa del target (BMI $\in [30, 35]$ per la classe *Obesity_Type_I*).

3. **Statistical Injection (Soft Rules):** Vengono fornite statistiche descrittive sommarie (media e deviazione standard delle variabili continue) estratte dal dataset reale, richiedendo al modello di utilizzarle come parametri per la generazione delle distribuzioni, preservando però la variabilità stocastica naturale.

4. **Output Formatting:** Vincolo rigoroso sul formato di output (CSV puro, separatore virgola, header incluso) per garantire l'immediata processabilità dei dati senza post-processing manuale.

Esempio di System Prompt (Estratto) Il prompt finale inviato al modello LLM integra vincoli deterministici e stocastici per massimizzare la fedeltà distributiva:

> *"Role: Biomedical Data Scientist. Task: Generate 350 synthetic rows for class 'Obesity_Type_I'.*
> ***Hard Constraints (Must be True):***
>
> - *Class is fixed: class = 'Obesity_Type_I'.*
> - *Domains: Use exact categorical levels (e.g., FCVC $\in$ {'Mai', 'A volte', 'Sempre'}).*
>
> ***Soft Constraints (Target Probabilities based on empirical distribution):***
>
> - ***Gender:*** *Male $\approx 56\%$, Female $\approx 44\%$.*
> - ***Family History Of Overweight:*** *'Si' $\approx 98\%$ (dominant trait).*
> - ***Habits:*** *'SMOKE' is extremely rare ($< 2\%$), 'SCC' (Calories monitoring) is almost non-existent ($< 1\%$).*
> - ***Transport:*** *'Automobile' ($\approx 67\%$) and 'Bicicletta' ($\approx 32\%$) cover 99% of cases. Public transport is negligible.*
> - ***Diet:*** *'FAVC' (High Caloric Food) is nearly ubiquitous ($\approx 97\%$).*
>
> ***Output:*** *Return ONLY the raw CSV data. No markdown."*

6.2 Procedura di generazione del dataset sintetico

La fase operativa di generazione non è stata lineare, ma ha richiesto un processo iterativo di raffinamento del prompt per allineare l'output del modello ai requisiti statistici stringenti.

6.2.1 Iterazioni e Ottimizzazione del Prompt

Va specificato che il template riportato nella Sezione 6.1.2 ha valore puramente esemplificativo e sintetizza la struttura logica finale. Il prompt effettivo, significativamente più esteso e dettagliato, è stato sviluppato attraverso molteplici tentativi sperimentali. Nelle prime iterazioni, infatti, il modello **GPT-5.2** ha mostrato difficoltà interpretative ricorrenti, tra cui:

- **Drift dei Domini Categorici:** Tendenza a inventare livelli non esistenti (es. "Rarely" invece di "Sometimes" per la variabile $CALC$) o a utilizzare etichette in inglese anziché quelle codificate nel dataset originale.
- **Disallineamento Matematico:** Generazione di coppie Peso/Altezza che, pur realistiche singolarmente, producevano un BMI fuori dal range target $[30, 35]$.
- **Mode Collapse:** Tendenza a ripetere profili "stereotipati" (righe identiche) per massimizzare la probabilità statistica a discapito della varianza naturale.

Solo integrando esplicitamente le distribuzioni empiriche come "Soft Constraints" (probabilità target per ogni categoria) e rafforzando i vincoli negativi ("Do not use X"), si è ottenuto un risultato soddisfacente.

6.2.2 Esecuzione, Parsing e Validazione

Una volta stabilizzato il prompt, l'inferenza è stata eseguita in modalità "Single-Shot Batch" richiedendo 350 osservazioni ($N_{syn} = 350$). L'output grezzo è stato sottoposto a parsing automatico e a un rigoroso controllo di qualità ("Sanity Check"):

1. **Validazione Formale:** Conferma dell'assenza di valori nulli (NaN) e verifica della conformità di tutti i valori categorici ai domini ammessi.

2. **Coerenza Calcolata:** Il BMI è stato ricalcolato ex-post a partire da $Weight$ e $Height$ generati, per garantire che la relazione funzionale fosse matematicamente esatta, correggendo eventuali approssimazioni del modello.

Il dataset finale, depurato da errori sintattici, costituisce la base per la valutazione comparativa.

6.3 Valutazione statistica dei dati sintetici

6.3.1 Confronto sulle variabili numeriche

La prima fase di valutazione riguarda la fedeltà distributiva (*distributional fidelity*) delle variabili numeriche tra dataset reale e dataset sintetico. In particolare, per ciascuna variabile quantitativa (*AGE, Height, Weight*) è stata confrontata la distribuzione tramite stima di densità kernel (KDE) sovrapposta, al fine di verificare se i dati sintetici replicano forma, posizione (tendenza centrale) e dispersione dei dati reali.

Dai grafici in Figura 39 emergono tre evidenze principali:

- **Peso (Weight):** il sintetico riproduce l'intervallo complessivo e la parte centrale della distribuzione, ma mostra una densità più concentrata tra ~ 90 e 110 kg e una riduzione della componente a pesi più bassi. Ciò suggerisce una tendenza del generatore a privilegiare valori maggiormente "centrali", riducendo parzialmente la multimodalità osservata nel reale.

- **Altezza (Height):** la densità sintetica appare più stretta e spostata verso valori medi/alti, con una minore presenza di altezze nel range più basso. Anche in questo caso, si osserva una contrazione della varianza rispetto al dataset reale.

- **Age:** il dataset sintetico riproduce correttamente la concentrazione principale dei soggetti nella fascia dei giovani adulti (circa 18–30 anni), ma tende ad attenuare la componente secondaria presente nel dataset reale verso età più elevate. Questo comportamento è compatibile con una generazione orientata ai profili più frequenti, con una minore copertura delle code distribuzionali.

Nel complesso, l'LLM ha mostrato una buona capacità di riprodurre gli ordini di grandezza e la regione centrale delle distribuzioni; tuttavia, la perdita di multimodalità e la contrazione delle code suggeriscono una fedeltà parziale, con tendenza alla concentrazione su profili tipici (*mode bias*).

6.3.2 Confronto sulle variabili qualitative

La seconda fase di valutazione riguarda le feature qualitative, confrontando la distribuzione delle categorie tra dataset reale e sintetico tramite barplot in percentuale. Questo tipo di analisi consente di verificare la *marginal fidelity* delle variabili discrete, individuando sia eventuali drift nelle proporzioni, sia difficoltà del generatore nel riprodurre categorie rare, aspetto tipico nella valutazione dei dati tabulari sintetici.

I risultati (Fig. 40– Fig. 41) mostrano un comportamento eterogeneo:

- **Variabili quasi-deterministiche (buona fedeltà):** *class* risulta correttamente costante, coerentemente con il vincolo hard impostato. Anche *SMOKE* e *SCC* mostrano una forte prevalenza della categoria dominante, in linea con il dataset reale, evidenziando che il modello riesce a mantenere vincoli su feature binarie altamente sbilanciate.

- **Variabili ordinali con sbilanciamento moderato (fedeltà parziale):** per *FAF* e *CAEC* il sintetico riproduce la gerarchia delle modalità (categoria più frequente correttamente dominante), ma tende a riallocare parte della massa di probabilità verso categorie meno frequenti, alterando l'intensità dello sbilanciamento.

- **Variabili con drift evidente:** *TUE*, *NCP*, *MTRANS*, *CH2O* e *CALC* presentano differenze più marcate tra reale e sintetico. In particolare:
  - *TUE* mostra un collasso verso la modalità principale nel sintetico (assenza quasi completa della modalità intermedia), suggerendo perdita di granularità nella generazione di categorie ordinali.
  - *NCP* enfatizza in modo eccessivo la modalità 3 nel sintetico, riducendo sensibilmente le modalità 1 e 2.
  - *MTRANS* altera il bilanciamento tra le modalità dominanti (Automobile vs Bicicletta), indicando una difficoltà nel riprodurre correttamente una distribuzione bimodale.
  - *CH2O* e *CALC* evidenziano spostamenti sistematici verso le categorie più frequenti nel sintetico, compatibili con una generazione "centralizzante".

In sintesi, l'LLM rispetta correttamente i vincoli di dominio (nessuna categoria fuori vocabolario) e replica bene le variabili fortemente sbilanciate o deterministiche; tuttavia, su feature ordinali/multimodali la fedeltà marginale risulta meno stabile, con tendenza a semplificare la distribuzione (riduzione di categorie intermedie) o a sovrastimare la modalità dominante.

6.3.3 Confronto su feature derivate

La terza fase di valutazione analizza la coerenza tra dataset reale e sintetico su tre *feature derivate*: *BMI*, *Activity_Index* e *Diet_Quality*. Il confronto è effettuato tramite sovrapposizione di stime di densità (KDE), con l'obiettivo di verificare l'allineamento tra posizione (tendenza centrale), dispersione e forma (unimodalità/multimodalità), poiché le feature derivate possono amplificare eventuali drift introdotti sulle variabili di input.

Dai grafici in Figura 42 emergono le seguenti evidenze:

- **BMI:** la distribuzione reale risulta relativamente regolare e continua, mentre il sintetico mostra una densità più "frastagliata", con picchi molto marcati e localizzati. Questo andamento suggerisce una generazione che concentra probabilità su un numero ridotto di valori/intervalli (effetto di *mass concentration*), riducendo la variabilità osservata nel reale e alterando la forma complessiva (possibile perdita di smoothness o discretizzazione implicita).

- **Activity_Index:** il dataset reale presenta una struttura multimodale con più massimi locali, mentre il sintetico tende a produrre una distribuzione più "spalmata" verso valori medio-alti, con una coda destra più pronunciata. In termini interpretativi, il sintetico sembra sovrastimare la frequenza di livelli di attività elevati e attenuare alcuni picchi caratteristici del reale, indicando un allineamento parziale della forma distributiva.

- **Diet_Quality:** il reale mostra una distribuzione con più componenti (picco principale e contributi secondari), mentre il sintetico concentra molta massa attorno al picco centrale, risultando più stretto nella regione principale. Inoltre, nel sintetico compare una piccola

massa in area di valori molto alti che nel reale è meno evidente, segnalando una riallocazione della probabilità verso estremi e una ridotta capacità di riprodurre fedelmente le componenti secondarie del reale.

Nel complesso, le feature derivate confermano un comportamento già osservabile su alcune variabili di base: buona riproduzione dell'ordine di grandezza e del "centro" della distribuzione, ma allineamento meno stabile su forma e dispersione, con tendenza a (i) concentrare massa su intervalli ristretti (BMI, Diet_Quality) oppure (ii) spostare la distribuzione verso valori più elevati (Activity_Index).

6.3.4 Verifica dell'adattamento a distribuzioni statistiche note

Oltre al confronto delle distribuzioni marginali tra dataset reale e sintetico, è stata condotta un'analisi esplorativa per valutare se le variabili sintetiche generate seguano distribuzioni statistiche note (es. Poisson, Normale, Bernoulli). L'obiettivo è determinare se il generatore LLM sia in grado di produrre dati con struttura probabilistica riconoscibile e coerente con modelli statistici standard, un indicatore importante della qualità della generazione sintetica.

Metodologia e selezione dei risultati Sono state esaminate tutte le variabili numeriche del dataset (sia discrete che continue) e gli indici derivati, verificando l'adattamento a distribuzioni teoriche plausibili (Poisson per conteggi, Normale per misure continue). Di seguito si riportano **esclusivamente le variabili che hanno mostrato un chiaro adattamento** a distribuzioni statistiche note. Le altre variabili analizzate non hanno evidenziato conformità a modelli probabilistici standard, presentando distribuzioni irregolari, multimodali o eccessivamente concentrate che non sono riconducibili a famiglie distributive note.

6.3.5 Variabili con adattamento a distribuzioni note

Distribuzione Normale:

- **Height (Altezza, $\mu = 1.69$, $\sigma = 0.10$)**: Il Q–Q plot mostra un allineamento complessivamente buono lungo la retta di riferimento, soprattutto nella regione centrale, suggerendo una normalità approssimata per la maggior parte della massa dei dati. Alle estremità si osservano leggere deviazioni dalla linearità e una struttura a "gradini" (quantili ripetuti), coerente con una misura discretizzata/arrotondata, che può accentuare scostamenti nelle code pur mantenendo un fit centrale adeguato. L'istogramma risulta compatibile con una forma a campana e la curva normale sovrapposta intercetta bene la densità empirica, con differenze più evidenti solo nelle code. Anche il confronto ECDF–CDF evidenzia un buon accordo nella parte centrale, con scostamenti contenuti verso i valori più bassi e più alti.

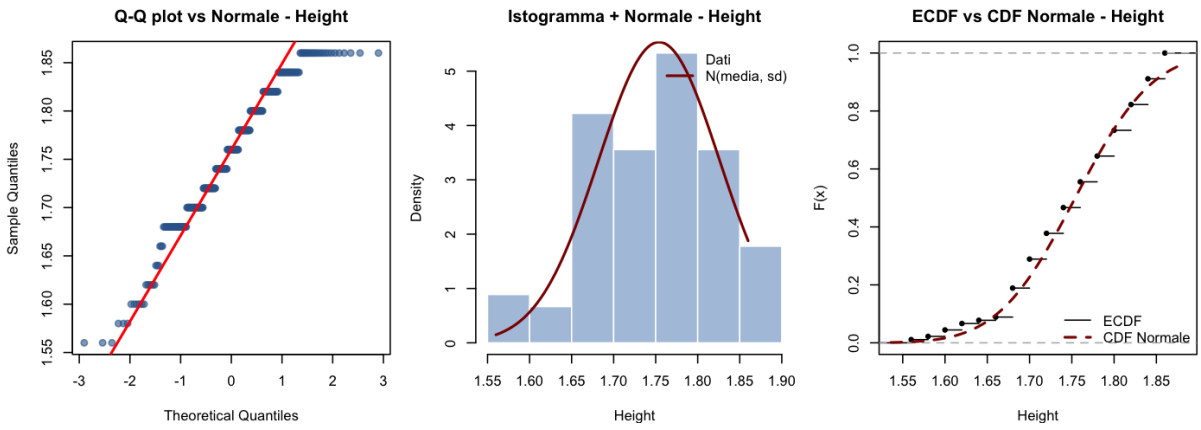

Figura 31: Analisi di normalità per la variabile Height. Da sinistra: Q-Q plot (allineamento perfetto sulla retta teorica), istogramma con densità normale sovrapposta, ECDF vs CDF normale. Tutti gli indicatori confermano l'adattamento gaussiano.

- **Weight (Peso, $\mu = 92.96$, $\sigma = 11.49$)**: Il Q–Q plot evidenzia una buona aderenza alla linearità, indicando che la distribuzione empirica è in larga misura descrivibile con una Normale almeno come approssimazione. Rispetto a *Height*, le deviazioni risultano più concentrate nelle code (in particolare agli estremi), come atteso in presenza di pochi valori molto bassi o molto alti e/o di lieve asimmetria residua. L'istogramma presenta una struttura unimodale ben rappresentata dalla densità $N(\mu, \sigma)$ stimata, a supporto dell'ipotesi di normalità come modello descrittivo. Il grafico ECDF–CDF mostra una sovrapposizione soddisfacente lungo gran parte del dominio, con differenze limitate nelle zone di coda.

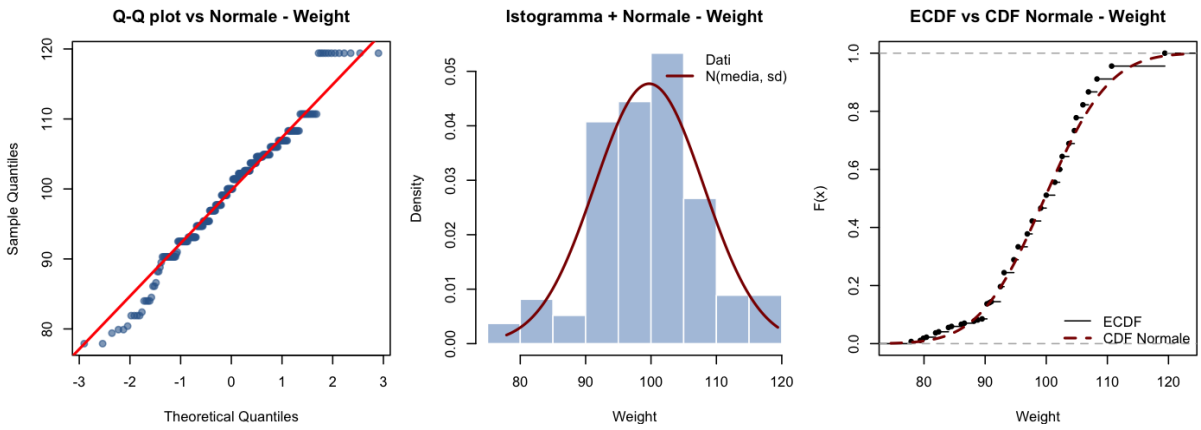

Figura 32: Analisi di normalità per la variabile Weight. Analogamente a Height, si osserva un eccellente adattamento alla distribuzione normale in tutti i test visuali (Q-Q plot, istogramma+densità, ECDF vs CDF).

Distribuzione Poisson: Nel presente studio, le variabili discrete del dataset (*FCVC*, *NCP*, *CAEC*, *CH2O*, *FAF*, *TUE*, *CALC*, *MTRANS*) sono state valutate per un eventuale adattamento alla distribuzione di Poisson. Tuttavia, l'analisi teorica rivela che tale modello è **inappropriato** per la natura di questi dati.

La distribuzione di Poisson è un modello probabilistico discreto concepito per modellare il numero di occorrenze di eventi rari e indipendenti in un intervallo di tempo o spazio fisso, caratterizzato da un tasso medio λ costante e un supporto illimitato ($k = 0, 1, 2, \ldots, \infty$).

Nel dataset in esame, molte variabili (es. FCVC, TUE) sono semanticamente **variabili ordinali codificate**, dove i numeri interi rappresentano fasce di frequenza o livelli qualitativi (es. 1="A volte", 2="Spesso") e non veri conteggi di eventi puntuali. Anche per variabili potenzialmente assimilabili a conteggi (come NCP, numero di pasti), la natura limitata e categorica delle risposte (valori in un set finito $\{1, 2, 3, 4\}$) ne suggerisce una trattazione come variabili discrete generiche piuttosto che come processi di conteggio poissoniani.

Pertanto, non essendo soddisfatte le assunzioni fondamentali (conteggi illimitati, indipendenza degli eventi, tasso costante), la distribuzione di Poisson non è applicabile correttamente a queste feature.

Distribuzione di Bernoulli: Tutte le variabili binarie del dataset (ad esempio Gender, family_history_with_overweight, FAVC, SMOKE) rientrano per definizione in una **distribuzione di Bernoulli**. Una variabile binaria può assumere soltanto due valori (tipicamente codificati come 0 e 1); ogni osservazione equivale a una singola prova di Bernoulli, in cui il "successo" (valore 1) ha probabilità p e l'"insuccesso" (valore 0) ha probabilità $1 - p$. Il fatto che p sia vicino a 0,5 oppure molto sbilanciato (ad esempio $p \approx 0{,}01$ per SMOKE) non modifica l'appartenenza alla famiglia Bernoulli: si tratta sempre di una variabile con due sole modalità, caratterizzata da un unico parametro p. Per ciascuna variabile binaria sono quindi stati stimati p, il relativo intervallo di confidenza al 95% e il test dell'ipotesi $H_0 : p = 0{,}5$.

6.4 Discussione dei risultati e criticità

Nel complesso, i confronti tra dataset reale e sintetico mostrano che il generatore è in grado di riprodurre in modo plausibile gli ordini di grandezza e le regioni centrali di molte distribuzioni (fedeltà sulle masse principali), mentre presenta criticità più evidenti nella riproduzione di code, multimodalità e categorie meno frequenti. Tale evidenza è coerente con quanto spesso riscontrato nella validazione di dati tabulari sintetici: la similarità marginale può risultare buona, pur non garantendo la preservazione della distribuzione congiunta e delle dipendenze tra variabili.

6.4.1 Risultati principali

Variabili numeriche Per le variabili numeriche analizzate (*AGE*, *Height*, *Weight*) il sintetico ricostruisce in modo complessivamente corretto la zona di massima densità, ma tende a ridurre la capacità di rappresentare componenti secondarie e/o valori in coda. Questo comportamento si manifesta tipicamente come *contrazione della dispersione* e attenuazione della multimodalità rispetto al reale, con un conseguente allineamento parziale della forma distributiva.

Variabili qualitative Per alcune variabili qualitative fortemente sbilanciate o vincolate si osserva un buon mantenimento della modalità dominante e dell'insieme di categorie ammissibili. Tuttavia, su variabili ordinali/multimodali emergono drift più marcati: alcune modalità intermedie risultano ridotte o quasi assenti (indicativo di semplificazione), mentre in altri casi la modalità dominante viene sovrastimata, alterando il profilo percentuale rispetto al reale. Queste differenze sono particolarmente rilevanti perché le feature qualitative costituiscono spesso input diretti per la costruzione di indici derivati, e quindi gli errori marginali possono propagarsi e amplificarsi nelle trasformazioni successive.

Feature derivate L'analisi delle KDE sulle feature derivate evidenzia scostamenti più netti rispetto a quelli osservati su molte variabili originali, suggerendo che la generazione non preservi in modo stabile la struttura complessiva sottostante alle trasformazioni.

In particolare, per *BMI* la distribuzione sintetica appare più irregolare, con picchi stretti e localizzati rispetto all'andamento più regolare del reale, suggerendo una concentrazione della probabilità su un insieme ristretto di intervalli/valori (riduzione della continuità effettiva). Per *Activity_Index* il sintetico mostra una maggiore massa su valori medio-alti e una coda destra più pronunciata, a fronte di una struttura reale più chiaramente multimodale; questo indica una ricostruzione parziale della forma e un possibile spostamento della distribuzione verso livelli di attività più elevati. Per *Diet_Quality* il sintetico tende a concentrare molta densità attorno al picco centrale, riducendo il contributo delle componenti secondarie visibili nel reale; inoltre compare una piccola massa su valori molto alti, segnalando una riallocazione di probabilità verso estremi poco rappresentati nel dataset reale.

6.4.2 Criticità e interpretazione

(1) Evidenza di semplificazione / perdita di diversità. La riduzione di modalità intermedie in alcune variabili ordinali e la tendenza a enfatizzare la modalità dominante sono segnali compatibili con fenomeni di semplificazione della distribuzione (talvolta descritti come *mode bias* o *mode collapse* in contesti generativi), soprattutto in presenza di categorie sbilanciate. La stessa "spigolatura" e concentrazione su pochi picchi osservata nel KDE del *BMI* è coerente con una generazione che non ricostruisce pienamente la variabilità continua del reale.

(2) Propagazione degli errori nelle trasformazioni. Le feature derivate sono funzioni (spesso non lineari o con pesature) di variabili originali: piccoli drift sulle marginali, o incoerenze tra variabili correlate, possono generare differenze più visibili sugli indici finali. Gli scostamenti su *Activity_Index* e *Diet_Quality* sono quindi interpretabili come indicatori indiretti di una preservazione non completa delle dipendenze tra le variabili comportamentali di partenza.

(3) Limite intrinseco del confronto puramente marginale. I grafici utilizzati (KDE e barplot) descrivono principalmente la fedeltà delle distribuzioni marginali, ma non sono sufficienti da soli a garantire che la distribuzione congiunta (e quindi le relazioni tra variabili) sia preservata. Per una validazione più robusta è utile affiancare metriche o test che considerino esplicitamente dipendenze multivariate (o proxy delle stesse), in modo da evitare che buone marginali mascherino incoerenze strutturali.

6.4.3 Implicazioni pratiche

Alla luce dei risultati, il dataset sintetico appare più affidabile per analisi descrittive di alto livello (ordini di grandezza, tendenze centrali e variabili fortemente sbilanciate), mentre richiede cautela quando l'obiettivo è preservare con precisione: (i) code e multimodalità, (ii) distribuzioni ordinali con modalità intermedie rilevanti, (iii) indici derivati sensibili a drift e dipendenze tra feature. In applicazioni downstream (es. modelli predittivi o analisi causali), tali criticità possono tradursi in stime distorte o in relazioni spurie/attenuate rispetto al reale, soprattutto se gli indici derivati entrano nel modello come variabili esplicative.

7 Conclusioni e sviluppi futuri

7.1 Risposte alle RQ

RQ1 (Qualità e coerenza dei dati): Dalle verifiche descrittive non emergono incoerenze macroscopiche di codifica o valori palesemente implausibili. Tuttavia si osservano sbilanciamenti marcati su alcune modalità qualitative e irregolarità nelle densità di alcune feature derivate, suggerendo possibili bias verso profili "tipici" e copertura incompleta di modalità meno frequenti.

RQ2 (Struttura e dipendenze tra variabili): Le correlazioni tra antropometria (caratteri misurabili del corpo umano) e stile di vita sono state esplorate tramite analisi bivariate e MCA. Emerge una forte correlazione peso-altezza ($r = 0.96$) e correlazioni moderate tra variabili comportamentali (es. FAF vs TUE: $V = 0.36$ secondo Cramér). La struttura dipendente è interpretabile nei dati reali, ma i confronti reale–sintetico evidenziano solo una buona fedeltà marginale.

RQ3 (Utilità delle feature in contesto one-vs-rest): In configurazione con sola classe Obesity Level 1, l'eterogeneità interna è descritta principalmente dalle variabili comportamentali/ordinali: l'analisi di Pareto (Sez. 5.3) identifica FAF, NCP e CH2O come le feature a maggiore entropia, mentre il clustering K-Means (Sez. 5.4) elegge FAVC e FCVC come discriminanti strutturali (ratio between/within maggiore). Le sole feature antropometriche risultano meno discriminanti all'interno della classe dato il range BMI ristretto (30.0–34.9).

RQ4 (Necessità ed efficacia di feature derivate): L'introduzione di Diet_Quality_Index e Activity_Index sintetizza informazione comportamentale in indicatori continui interpretabili. Nei dati reali, il DQI mostra forte correlazione positiva con CH2O ($r = 0.91$) e correlazione negativa con FAVC ($r = -0.56$), confermando coerenza strutturale. Tuttavia, **entrambi gli indici mostrano correlazione trascurabile con il BMI** ($r = -0.06$ per DQI, $r = -0.04$ per AI), suggerendo che all'interno della classe Obesity I il peso corporeo non è associato linearmente alle abitudini comportamentali attuali.

RQ5 (Fedeltà statistica dei dati sintetici): I dati sintetici preservano gli ordini di grandezza e la massa centrale delle distribuzioni principali, ma presentano limitazioni quantificabili:

- **Variabili numeriche:** I confronti tramite KDE (Sez. 6.3.1, Fig. 39) mostrano sovrapposizione sulla parte centrale per Height e Weight, ma con densità sintetica più concentrata e varianza ridotta. AGE mostra attenuazione della componente verso età più elevate. **Test di adattamento a distribuzioni note** (Sez. 6.3.4): Height e Weight sintetici seguono distribuzione normale (Q-Q plot allineati, densità kernel sovrapponibile), le variabili binarie seguono Bernoulli, mentre altre variabili non mostrano conformità a modelli standard.

- **Variabili qualitative:** I confronti percentuali (Fig. 40–41) evidenziano rispetto dei domini (nessuna categoria fuori vocabolario), ma drift visibili su diverse variabili: TUE mostra collasso verso la modalità principale con quasi totale assenza della categoria intermedia; NCP enfatizza eccessivamente la modalità 3; MTRANS altera il bilanciamento tra le modalità dominanti Automobile e Bicicletta. Le variabili quasi-deterministiche (SMOKE, SCC, class) mantengono correttamente la categoria dominante.

- **Feature derivate:** BMI sintetico presenta KDE "frastagliata" con picchi molto marcati e localizzati, suggerendo concentrazione su intervalli ristretti (mass concentration). Activity_Index mostra distribuzione spostata verso valori medio-alti con coda destra più pronunciata. Diet_Quality concentra densità attorno al picco centrale riducendo le componenti secondarie visibili nel reale.

Sintesi: fedeltà accettabile sulle statistiche aggregate delle variabili principali, ma preservazione incompleta di multimodalità, code distribuzionali e modalità intermedie nelle variabili ordinali.

RQ6 (Diversità e rischio di mode collapse): Dall'analisi comparativa emergono evidenze di riduzione di diversità:

- **Categorie intermedie ridotte o assenti:** Variabili ordinali mostrano semplificazione della distribuzione con perdita di granularità. In particolare, TUE presenta quasi totale assenza della modalità intermedia nel sintetico, mentre CALC e FAF mostrano riallocazione della massa.
- **Modalità rare sotto-rappresentate:** Le categorie meno frequenti nei dati reali tendono a essere ulteriormente compresse o quasi eliminate nei sintetici (es. fumatori in SMOKE, livello "Sempre" in CAEC).
- **Concentrazione su profili tipici:** Le distribuzioni sintetiche tendono sistematicamente a sovrastimare le modalità dominanti e a ridurre la presenza di combinazioni meno frequenti, comportamento compatibile con generazione orientata ai pattern più probabili (*mode bias*).
- **Perdita di smoothness nelle feature derivate:** Le KDE delle feature derivate (in particolare BMI) mostrano densità meno regolari nel sintetico rispetto al reale, con picchi stretti e localizzati che indicano discretizzazione implicita o concentrazione su valori specifici.

7.2 Limiti del lavoro

Questo lavoro fornisce una valutazione descrittiva e comparativa (reale vs sintetico) focalizzata su coerenza dei valori, distribuzioni marginali e alcuni indicatori derivati. Di conseguenza, le conclusioni devono essere lette tenendo conto dei limiti riportati di seguito, che riguardano sia i dati sia la metodologia di validazione adottata.

7.2.1 Limiti legati al dataset

- **Validità esterna ridotta (one-vs-rest, singola classe).** Il dataset è in configurazione *one-vs-rest* e contiene un'unica classe (*Obesity Level 1*); pertanto, i pattern osservati descrivono l'eterogeneità *intra-classe* e non consentono inferenze robuste su separabilità tra classi o generalizzazione a popolazioni con distribuzioni diverse.
- **Possibili bias di campionamento non verificabili con certezza.** Anche in assenza di valori palesemente implausibili, un dataset può riflettere selezioni non casuali (es. sovra/sotto-rappresentazione di profili comportamentali), che non sono completamente diagnosticabili con i soli confronti grafici effettuati in questo lavoro.
- **Assenza di variabili potenzialmente confondenti.** Le relazioni tra antropometria e stile di vita possono dipendere da fattori non osservati (es. contesto socioeconomico, comorbidità, misure temporali), non disponibili nel dataset e quindi non controllabili nell'analisi.

7.2.2 Limiti metodologici di validazione

- **Enfasi su confronti marginali e descrittivi.** La valutazione è stata condotta principalmente tramite KDE e barplot percentuali, strumenti utili per confronti esplorativi ma non sufficienti, da soli, a garantire la preservazione della distribuzione *congiunta* e delle dipendenze tra feature.

- **Dipendenze tra variabili non quantificate in modo esaustivo.** Anche quando le marginali risultano simili, la correlazione (anche non lineare) tra feature può essere alterata; la letteratura evidenzia che questo è un punto critico nella validazione di dati tabulari sintetici e richiede metriche multivariate o stime di divergenza sulla distribuzione congiunta.
- **Sensibilità dei grafici a scelte tecniche.** Le KDE dipendono da scelte di bandwidth e smoothing: picchi o "frastagliature" possono essere amplificati o attenuati dalla parametrizzazione, per cui l'interpretazione deve rimanere prudente, soprattutto quando si osservano densità sintetiche molto irregolari (es. BMI).
- **Assenza di test/statistiche di distanza standardizzati nel pipeline.** Non sono state riportate metriche quantitative unificate (es. divergenze per feature, metriche multivariate, test formali sulle distribuzioni), quindi una parte delle conclusioni resta qualitativa e dipendente dalla lettura dei grafici.

7.2.3 Limiti sulle feature derivate

- **Propagazione del drift dagli input agli indici.** *Diet_Quality* e *Activity_Index* dipendono da variabili comportamentali/ordinali: differenze anche moderate sulle categorie di partenza possono amplificarsi sugli indici finali, rendendo più evidente lo scostamento tra reale e sintetico.
- **Dipendenza dal design dell'indice.** Gli indici derivati riflettono scelte progettuali (pesi, normalizzazioni, mappature ordinali) che non sono univoche; quindi risultati diversi potrebbero emergere con definizioni alternative, pur partendo dagli stessi dati.

7.2.4 Riproducibilità e robustezza della generazione

Approccio iterativo con validazione visiva. La generazione dei dati sintetici è stata condotta tramite un processo iterativo di raffinamento del prompt. Nelle **prime 3–4 iterazioni**, il modello ha prodotto output con criticità evidenti identificate mediante ispezione visiva: valori numerici fuori dai range plausibili (es. BMI non coerenti con la classe target), invenzione di categorie non presenti nel dataset originale, e distribuzioni fortemente sbilanciate.

Dopo l'introduzione di vincoli probabilistici espliciti (*soft constraints* basati sulle frequenze empiriche) e il rafforzamento dei vincoli negativi nel prompt, le **successive 2–3 generazioni** hanno mostrato distribuzioni visivamente stabili e coerenti con i dati reali: sovrapposizione accettabile delle KDE sulle variabili numeriche, allineamento delle frequenze categoriche (scostamenti $< 10\%$ per le modalità dominanti), e assenza di violazioni dei vincoli hard.

Limiti metodologici riconosciuti. L'approccio presenta due limitazioni principali: (i) *assenza di metriche quantitative*: non è stata definita una funzione obiettivo numerica (es. divergenza KL, distanza di Wasserstein) per quantificare oggettivamente il miglioramento tra iterazioni, rendendo la valutazione dipendente dal giudizio qualitativo dell'analista; (ii) *variabilità stocastica non controllata*: non sono state eseguite replicazioni controllate della generazione finale (stesso prompt, seed diversi), impedendo la stima della variabilità intrinseca del processo e l'esclusione di potenziali differenze significative tra esecuzioni diverse.

La scelta di procedere con validazione manuale è stata dettata da vincoli di tempo del progetto accademico e dalla natura esplorativa dello studio (*proof-of-concept*), ma per applicazioni in contesti critici si raccomanda l'adozione di protocolli strutturati con seed documentato, metriche di distanza distribuzionale e test di stabilità su replicazioni multiple.

A Appendice A: Formule e dettagli di calcolo

A.1 Notazione generale

Sia $\{x_1, \ldots, x_n\}$ un campione di n osservazioni di una variabile quantitativa X. Per una variabile qualitativa con modalità $k \in \{1, \ldots, K\}$, indichiamo con n_k la frequenza assoluta della modalità k e con f_k la frequenza relativa.

A.2 Frequenze relative e percentuali (variabili qualitative)

Le frequenze relative sono calcolate come

$$f_k = \frac{n_k}{n},$$

mentre le percentuali riportate nei barplot sono

$$\%_k = 100 \cdot f_k = 100 \cdot \frac{n_k}{n}.$$

A.3 Stima di densità kernel (KDE)

Per confrontare le distribuzioni delle variabili numeriche e degli indici derivati è stata utilizzata la KDE. La stima di densità kernel in un punto x è definita come

$$\hat{f}_h(x) = \frac{1}{nh} \sum_{i=1}^{n} K\left(\frac{x - x_i}{h}\right),$$

dove $K(\cdot)$ è la funzione kernel e $h > 0$ è il parametro di smoothing (bandwidth).

A.4 Body Mass Index (BMI)

Il BMI è stato calcolato in unità metriche tramite la formula standard:

$$\text{BMI} = \frac{\text{Weight (kg)}}{\text{Height (m)}^2}.$$

A.5 Feature derivate (indici)

In questo lavoro sono state considerate due feature sintetiche derivate dalle variabili comportamentali: *Diet_Quality* e *Activity_Index*.

Forma generale (normalizzazione e combinazione). Quando un indice è costruito combinando più componenti (eventualmente normalizzate), una forma generale (utile anche per documentare i passaggi di calcolo) è:

$$I = \frac{\sum_{j=1}^{p} w_j \, s_j}{\sum_{j=1}^{p} w_j},$$

dove s_j è il punteggio/score associato alla j-esima componente e w_j è il peso assegnato.

Normalizzazione (se applicata). Se una componente numerica z viene riportata nell'intervallo $[0, 1]$ tramite min–max scaling:

$$z^* = \frac{z - \min(z)}{\max(z) - \min(z)}.$$

Diet_Quality e Activity_Index (formula operativa). Le formule operative e la definizione dei punteggi s_j (mappatura delle modalità ordinali/binarie e pesi) sono quelle riportate nel materiale di calcolo del progetto.

B Appendice B: Materiale supplementare

In questa appendice sono riportate le visualizzazioni di supporto relative alla validazione delle feature derivate e al confronto tra dataset reale e sintetico. Le figure sono organizzate in tre sottosezioni tematiche per facilitare la consultazione.

B.1 Validazione del Diet Quality Index (DQI)

Le figure seguenti documentano la validazione interna del *Diet Quality Index*, mostrandone la coerenza con le componenti di partenza, la distribuzione nel campione analizzato e la relazione con il BMI.

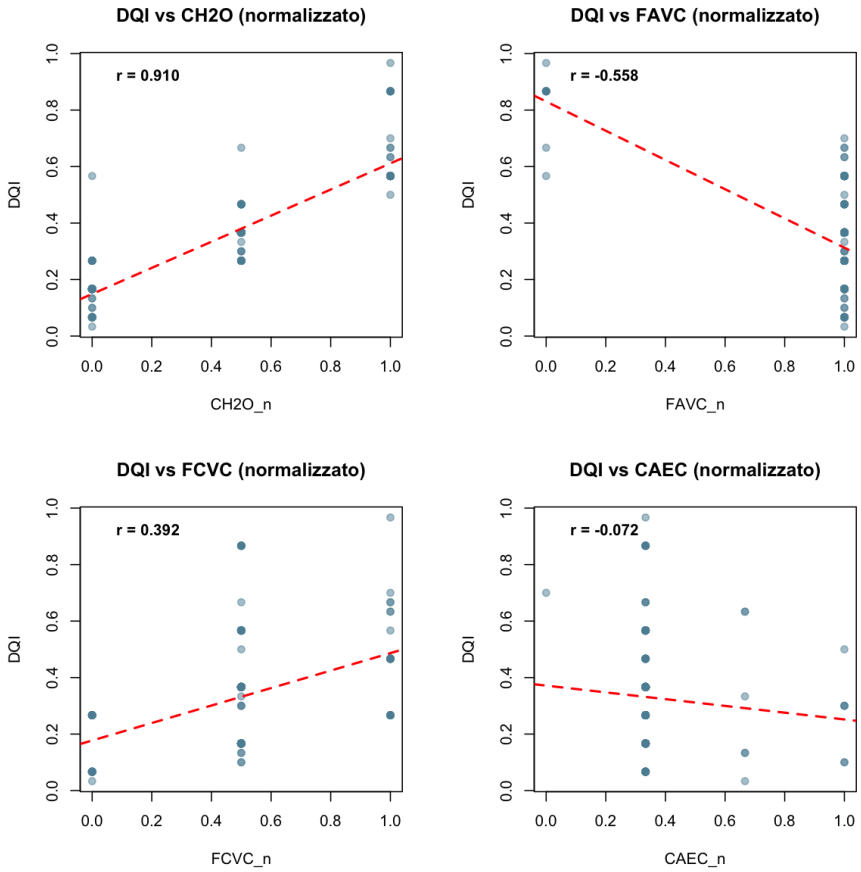

Figura 33: Validazione interna del Diet Quality Index (DQI). Gli scatterplot mostrano la relazione tra l'indice sintetico (asse Y) e le sue componenti costitutive normalizzate. Si evidenzia una forte dipendenza lineare positiva con il consumo d'acqua (CH2O, $r = 0.91$) e una correlazione negativa con l'assunzione di cibi calorici (FAVC, $r = -0.56$), confermando la coerenza strutturale dell'indice. La disposizione regolare dei punti è dovuta alla natura discreta delle variabili di input.

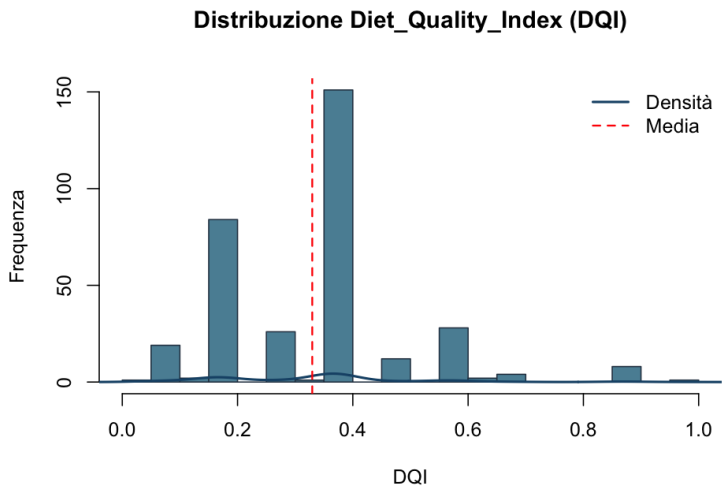

Figura 34: Distribuzione di frequenza del Diet Quality Index nel campione. La curva di densità (blu scuro) e la media (linea tratteggiata rossa a 0.33) indicano una prevalenza di abitudini alimentari di qualità medio-bassa. La distribuzione non è gaussiana ma presenta picchi in corrispondenza delle combinazioni di risposte più frequenti.

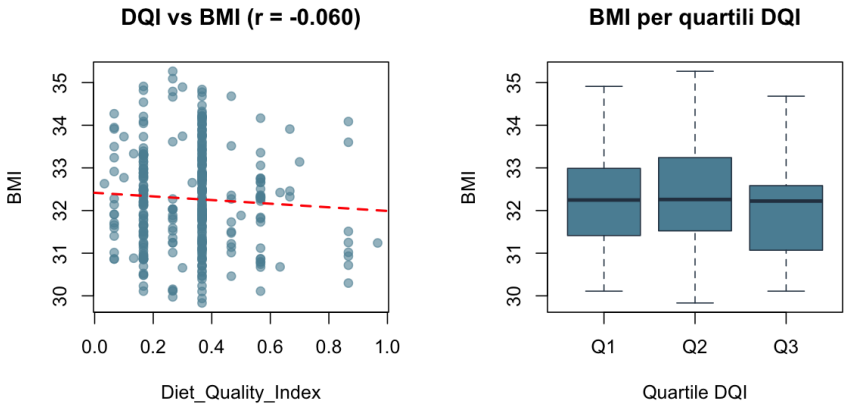

Figura 35: Analisi della relazione tra Diet Quality Index e BMI. A sinistra: Scatterplot che evidenzia l'assenza di correlazione lineare ($r \approx -0.06$) tra qualità della dieta e indice di massa corporea. A destra: Boxplot del BMI stratificato per quartili di DQI; la sovrapposizione delle distribuzioni conferma che, all'interno del cluster Obesity Type I, un miglioramento della dieta (quartile Q3) non è statisticamente associato a un BMI inferiore rispetto a diete peggiori (quartile Q1).

B.2 Validazione dell'Activity Index (AI)

Le figure seguenti documentano la validazione dell'*Activity Index*, analizzando la relazione con le sue componenti, la distribuzione nel campione e l'associazione con il BMI.

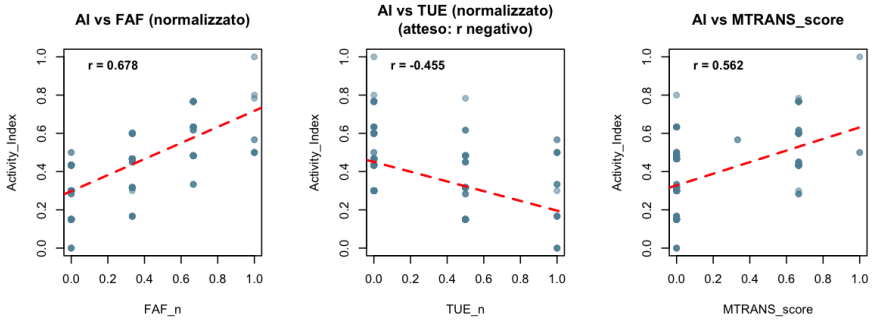

Figura 36: Validazione dell'Activity Index (AI). L'indice sintetico mostra correlazioni positive coerenti con l'attività fisica (FAF) e la mobilità attiva (MTRANS), e negativa con la sedentarietà (TUE).

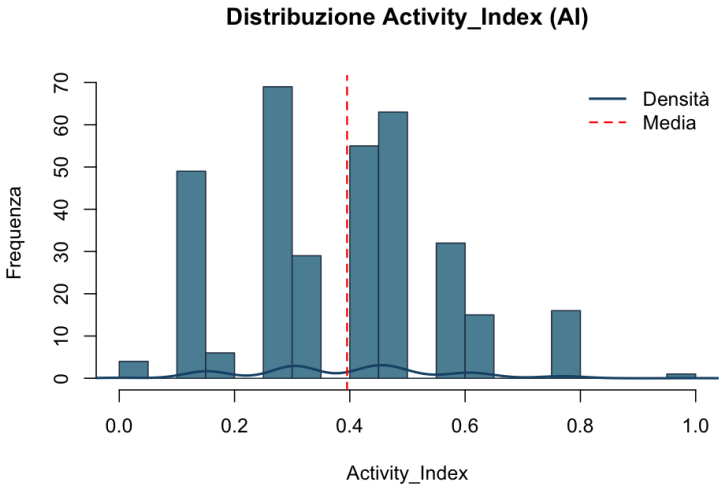

Figura 37: Distribuzione dell'Activity Index. La forma multimodale evidenzia la presenza di cluster comportamentali distinti all'interno della popolazione.

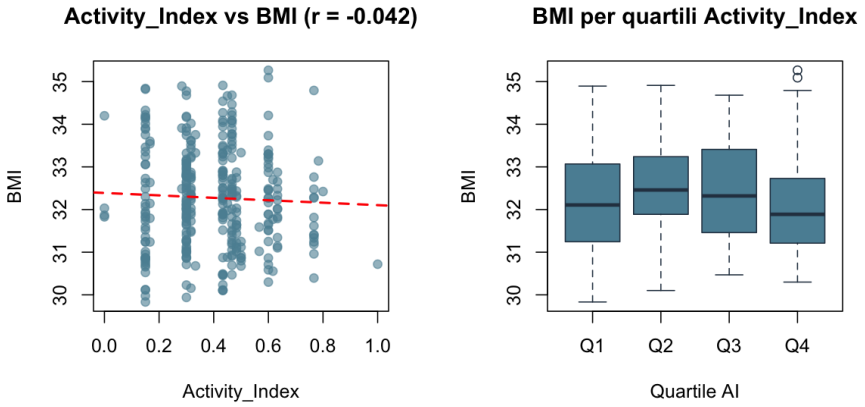

Figura 38: Relazione tra Activity Index e BMI. Anche per l'attività fisica si conferma l'assenza di correlazione significativa con l'indice di massa corporea ($r \approx -0.04$). I soggetti più attivi (Quartile 4) non mostrano un BMI medianamente inferiore rispetto ai sedentari (Quartile 1) in questo campione.

B.3 Confronto tra dati reali e sintetici

Le figure seguenti presentano un confronto sistematico tra le distribuzioni delle variabili nel dataset reale e in quello sintetico generato tramite LLM, organizzate per tipologia di feature.

B.3.1 Variabili numeriche

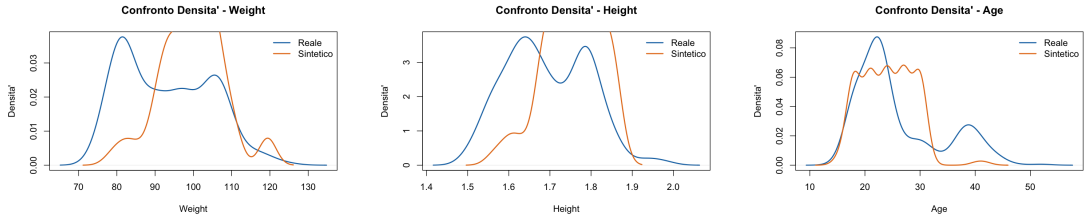

Figura 39: Confronto tra distribuzioni delle variabili numeriche nei dati reali e sintetici tramite KDE sovrapposte.

B.3.2 Variabili qualitative

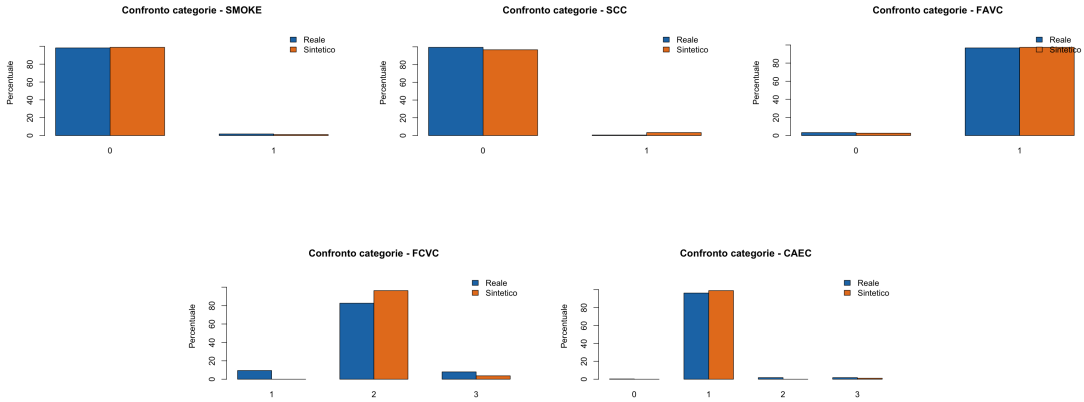

Figura 40: Confronto percentuale tra distribuzioni delle principali variabili qualitative (reale vs sintetico).

B.3.3 Feature derivate

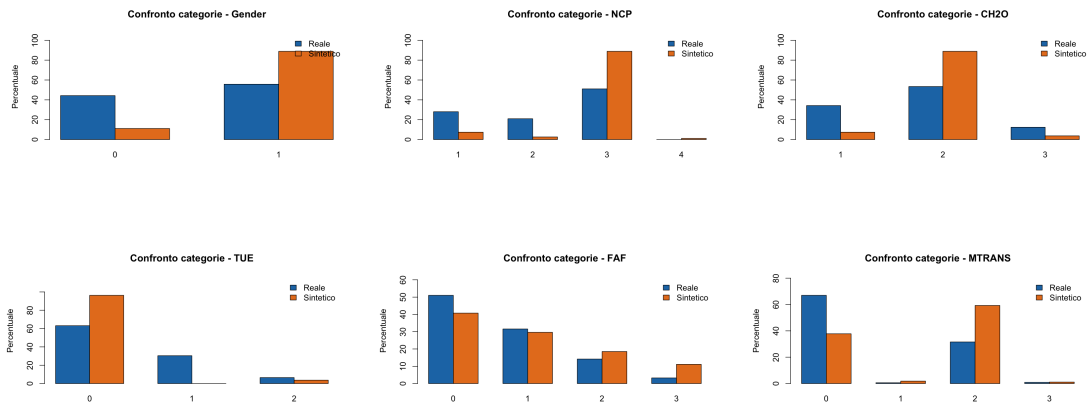

Figura 41: Confronto percentuale tra distribuzioni qualitative: variabili ordinali e di mobilità (reale vs sintetico).

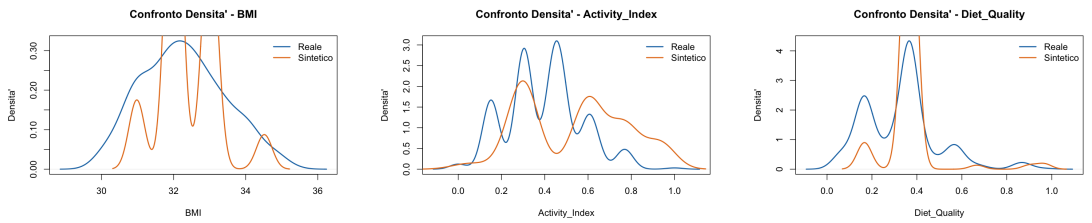

Figura 42: Confronto tra distribuzioni (KDE) delle feature derivate nei dati reali e sintetici.

B.4 Analisi sulle distribuzioni

B.4.1 Distribuzione Normale

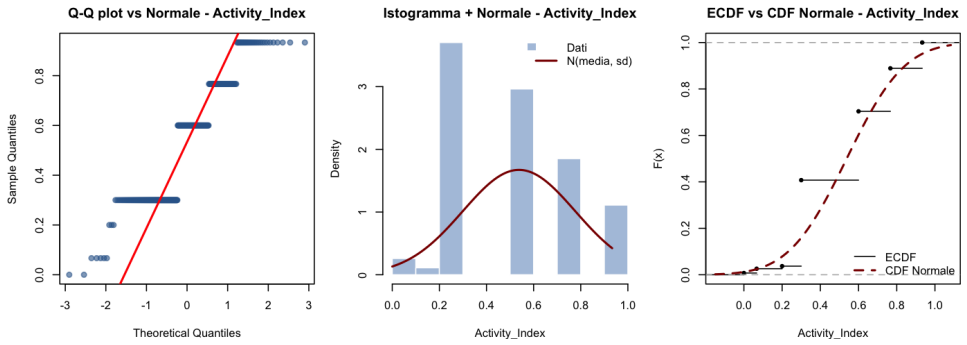

Figura 43: Verifica di normalità per la variabile `Activity_Index`: Q-Q plot vs normale (sinistra), istogramma con densità N(media, sd) (centro), ECDF vs CDF normale (destra).

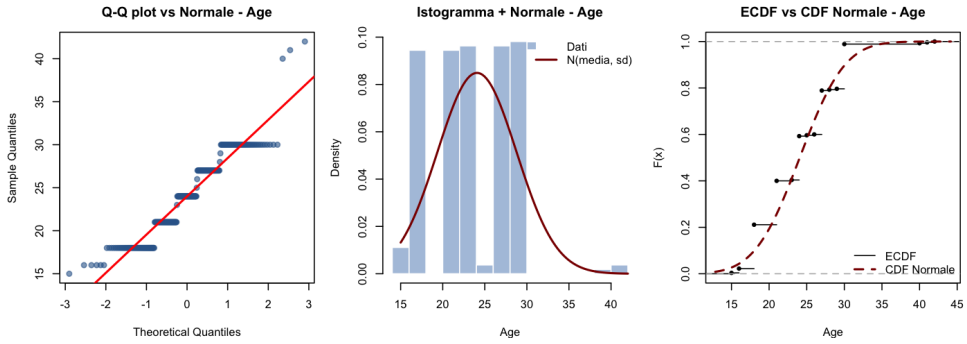

Figura 44: Verifica di normalità per la variabile `AGE`: Q-Q plot vs normale (sinistra), istogramma con densità N(media, sd) (centro), ECDF vs CDF normale (destra).

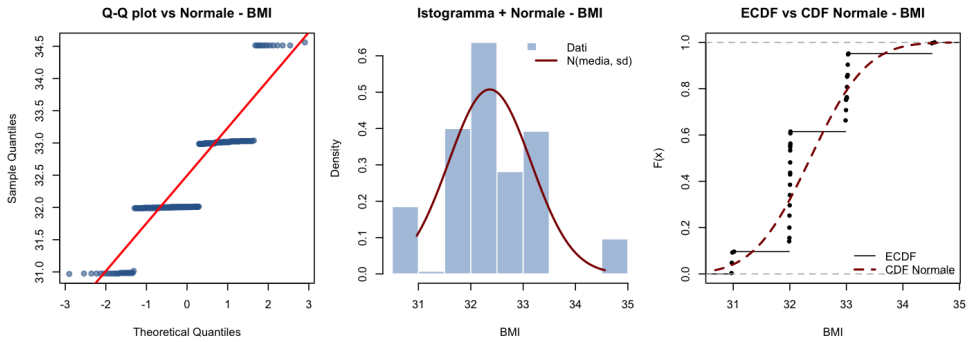

Figura 45: Verifica di normalità per la variabile `BMI`: Q-Q plot vs normale (sinistra), istogramma con densità N(media, sd) (centro), ECDF vs CDF normale (destra).

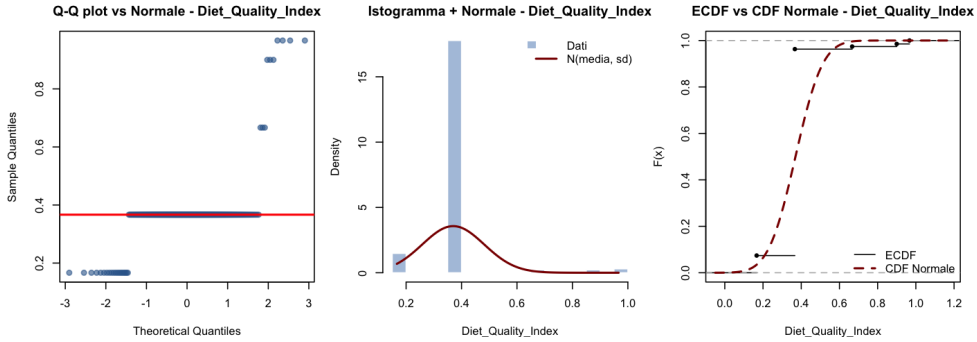

Figura 46: Verifica di normalità per la variabile `Diet_Quality_Index`: Q-Q plot vs normale (sinistra), istogramma con densità N(media, sd) (centro), ECDF vs CDF normale (destra).

B.4.2 Distribuzione di Bernoulli

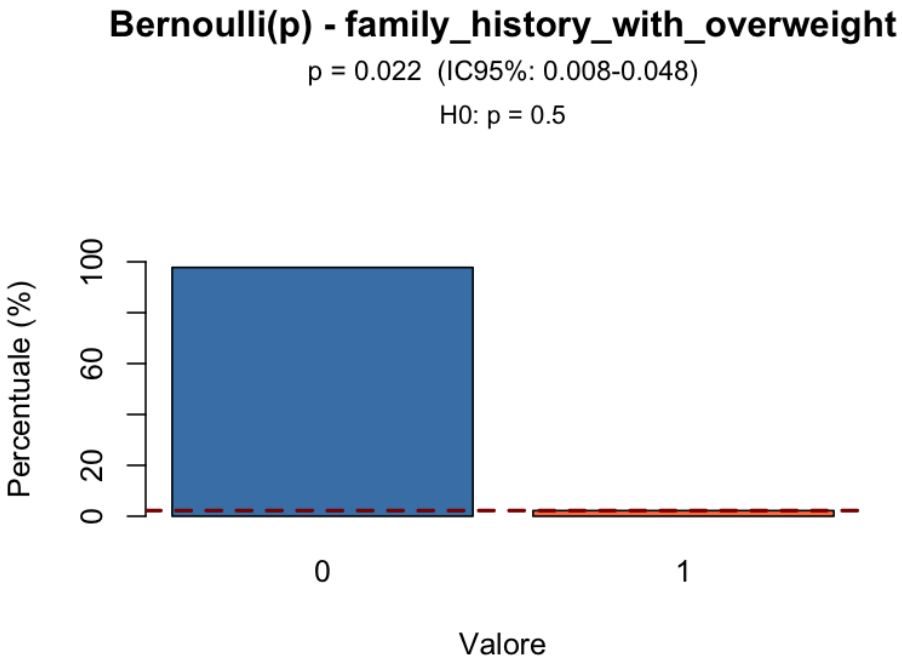

Figura 47: Adattamento alla distribuzione di Bernoulli per la variabile `family_history_with_overweight`: barre delle percentuali per i valori 0 e 1, stima di p, intervallo di confidenza al 95% e ipotesi $H_0 : p = 0{,}5$.

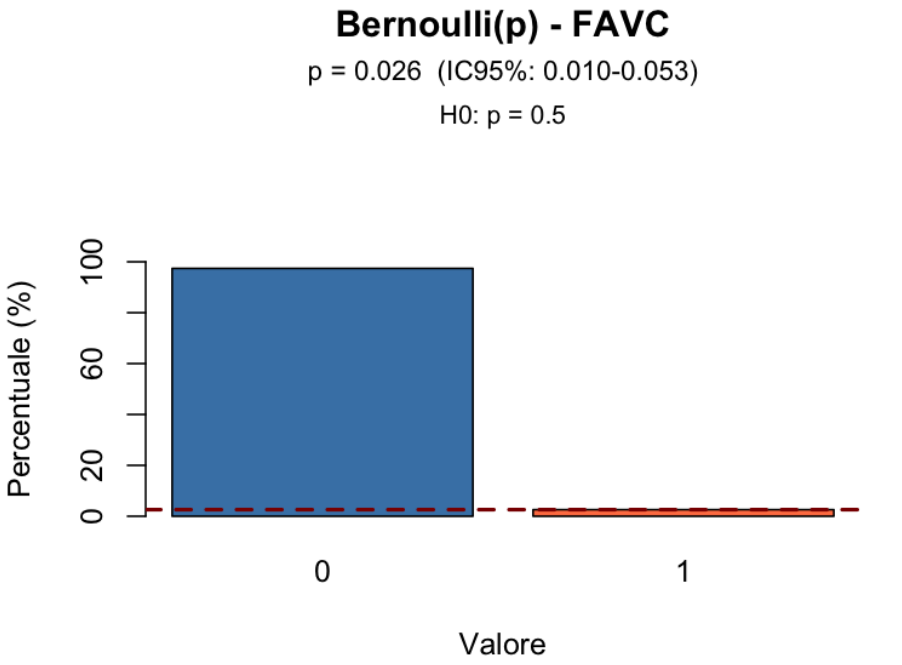

Figura 48: Adattamento alla distribuzione di Bernoulli per la variabile `FAVC`: barre delle percentuali per i valori 0 e 1, stima di p, intervallo di confidenza al 95% e ipotesi $H_0 : p = 0{,}5$.

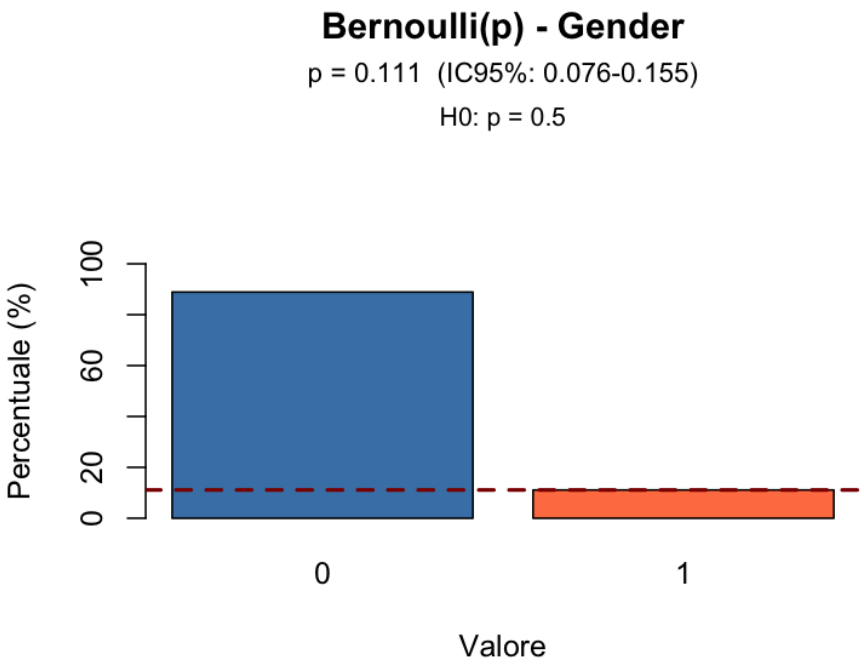

Figura 49: Adattamento alla distribuzione di Bernoulli per la variabile `Gender`: barre delle percentuali per i valori 0 e 1, stima di p, intervallo di confidenza al 95% e ipotesi $H_0 : p = 0{,}5$.

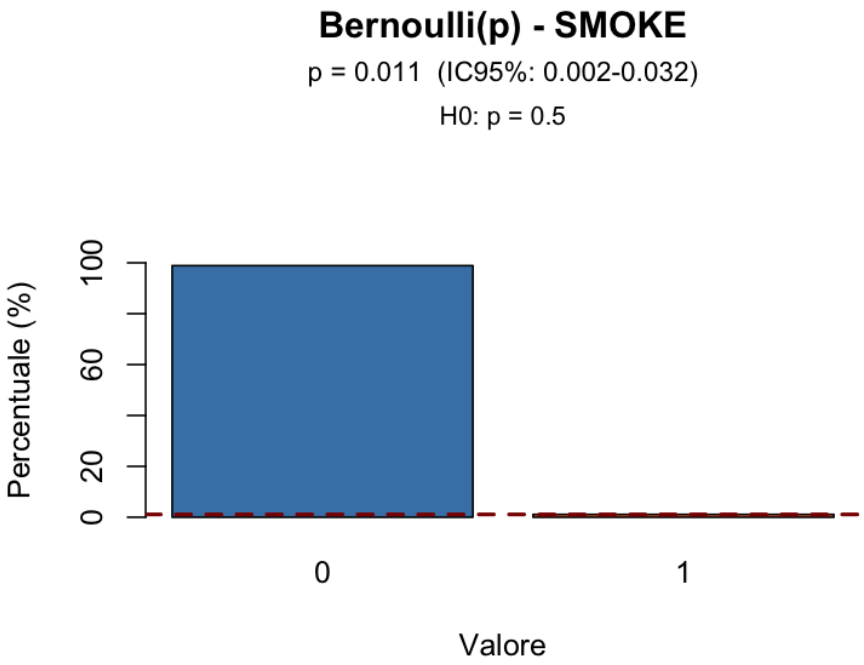

Figura 50: Adattamento alla distribuzione di Bernoulli per la variabile `SMOKE`: barre delle percentuali per i valori 0 e 1, stima di p, intervallo di confidenza al 95% e ipotesi $H_0 : p = 0{,}5$.

Riferimenti bibliografici

[1] Artificial Analysis. *LLM Leaderboard - Comparison of over 100 AI models*. https://artificialanalysis.ai/leaderboards/models. Accessed: February 2026. 2026.

[2] Fabio Mendoza Palechor e Alexis De la Hoz Manotas. «Dataset for estimation of obesity levels based on eating habits and physical condition in individuals from Colombia, Peru and Mexico». In: *Data in Brief* 25 (2019), p. 104344. DOI: 10.1016/j.dib.2019.104344. URL: https://pubmed.ncbi.nlm.nih.gov/31467953/.

[3] UCI Machine Learning Repository. *Estimation of Obesity Levels Based On Eating Habits and Physical Condition*. UCI Machine Learning Repository, dataset ID 544. 2019. DOI: 10.24432/C5H31Z. URL: https://archive.ics.uci.edu/dataset/544/estimation+of+obesity+levels+based+on+eating+habits+and+physical+condition.